

성과감사



감 사 보 고 서

- 인공지능산업 육성실태Ⅲ -
(AI 학습용 데이터 구축사업 중심)

2026. 7.

감 사 원

목 차

제1장 감사실시 개요	1
제2장 인공지능 학습용 데이터 구축 현황	5
제1절 인공지능 관련 정책 추진 개요	5
제2절 인공지능 학습용 데이터 현황	7
제3절 인공지능 학습용 데이터 구축 절차	10
제4절 인공지능 학습용 데이터 품질관리	12
제3장 분야별 감사결과	15
제1절 감사결과 총괄	15
제2절 학습용 데이터 구축계획 분야	18
제3절 학습용 데이터 품질관리 분야	33
제4절 학습용 데이터 사후관리 분야	49
제4장 종합 결론	58
제1절 감사결과 총평	58
제2절 감사의 기대효과 및 한계	59

표 목차

[표 1] 분야별 감사 중점	3
[표 2] 인공지능 관련 주요 정책 수립 현황	6
[표 3] 일반 데이터와 인공지능 학습용 데이터의 차이	7
[표 4] 인공지능 학습용 데이터 구축 사업 추진 현황(2017~2024년)	9
[표 5] 인공지능 학습 방식	10
[표 6] 인공지능 학습용 데이터 구축 절차	11
[표 7] 인공지능 학습용 데이터 주요 유형	11
[표 8] 인공지능 학습용 데이터 품질관리 원칙	13
[표 9] 인공지능 학습용 데이터 품질지표	13
[표 10] 데이터 품질인증기관 지정 및 품질인증 수행 절차	14
[표 11] 분야별·기관별 감사결과 통보 현황	15
[표 12] 인공지능 학습용 데이터 공개 현황	18
[표 13] 인공지능 학습용 데이터 통합제공체계 추진과제	21
[표 14] 인공지능 학습용 데이터 유사성 분석 기준	23
[표 15] 인공지능 학습용 데이터를 새로 구축한 사례	24
[표 16] 생활폐기물 학습용 데이터의 학습 대상 및 이미지 비교	26
[표 17] 야생동물 학습용 데이터 학습 대상 및 이미지 비교	27
[표 18] 인공지능 학습용 데이터를 같은 연도에 구축한 사례	28
[표 19] 알약 학습용 데이터 학습 대상 및 이미지 비교	29
[표 20] 구강 학습용 데이터 학습 대상 및 이미지 비교	31
[표 21] 인공지능 학습용 데이터 품질관리 가이드라인	34
[표 22] 인공지능 학습용 데이터 및 공공데이터 공개 현황	34
[표 23] 점검기준별 분석결과 총괄	37
[표 24] 인공지능 학습용 데이터 품질지표 및 내용	39
[표 25] 인공지능 학습용 데이터 구문 정확성 검사 실시가 어려운 기관 현황	41
[표 26] 인공지능 학습용 데이터 6종의 구문 정확성 검사 결과	42
[표 27] 인공지능 학습용 데이터와 데이터베이스(DB) 데이터의 비교	44
[표 28] 서울특별시 '대형폐기물 학습데이터' 관련 JSON 파일과의 이미지 매칭률	46
[표 29] 사업수행기관 폐업 및 관련 학습용 데이터 구축 현황	52
[표 30] 폐업한 주관기관의 학습용 데이터 관련 민원 내역	54
[표 31] 폐업한 참여기관의 학습용 데이터 관련 민원 내역	55

그림 목차

[그림 1] AI Hub를 통한 인공지능 학습용 데이터 공개 구조	8
[그림 2] 인공지능 학습을 위한 데이터 가공(예시)	12
[그림 3] 인공지능 학습용 데이터 품질검증 프로세스	14
[그림 4] 인공지능 학습용 데이터 품질관리	35
[그림 5] 인공지능 학습용 데이터 구축 절차 및 품질	40
[그림 6] 구문 정확성 지표 검사 절차	41
[그림 7] 한국도로공사 ‘도로주행 CCTV 학습데이터셋’ 어노테이션 오류	44
[그림 8] 서울특별시 ‘대형폐기물 학습데이터’ 관련 JSON 파일과 다른 이미지(예시)	46

제1장 감사실시 개요

제1절 감사배경 및 목적

세계 주요 국가들은 다양한 산업 분야에서 인공지능(AI: Artificial Intelligence) 기술 사용이 확대되면서 시장 규모가 고속성장¹⁾할 것으로 전망됨에 따라 인공지능 기술·시장 선점을 위해 연구개발 투자 확대, 인프라 구축, 인재양성 등 다양한 지원 정책을 추진하고 있으며, 우리나라도 2019년 12월 최초의 인공지능 종합대책인 “인공지능 국가전략”을 수립하는 등 디지털 전환 가속화에 대비하고 있다.

최근 인공지능 기술은 범용 기술로서 전통적인 의미의 정보통신 분야뿐만 아니라 제조업과 금융, 물류 등 각 분야의 생산성과 효율성을 높일 수 있다는 특징이 있어 기술 선점을 위한 국가 간 경쟁이 치열하게 전개되고 있다.

한편, 2022년 11월 챗GPT 등장 이후 인공지능 기술의 중심이 사물 식별 등 ‘분류형 인공지능’에서 방대한 데이터를 스스로 학습하여 문장, 이미지 등을 직접 만들어내는 ‘생성형 인공지능’으로 이동하여 산업 전반의 혁신을 주도하고 있다.

우리 정부 역시 2017년부터 1조 6,328억 원을 투입하여 인공지능 학습용 데이터 구축사업을 추진하면서, 2023년 4월 “초거대 AI 경쟁력 강화 방안”을 수립하는 등 초거대 인공지능 확산 생태계 조성을 핵심 국정과제로 선정하고, 2024년부터는 초거대 인공지능 개발을 위한 데이터 지원을 강화하기 위해 해당 사업을 ‘초거대 AI 확산 생태계 조성사업’으로 전환하는 등 고품질 인공지능 생태계 기반

1) 2023년 9월 국제 시장조사 기관인 마켓앤마켓(MarketsandMarkets)의 보고서에 따르면 세계 인공지능 시장 규모는 2023년 1,502억 달러에서 2030년에는 1조 3,452억 달러로 연평균 36.8%씩 성장할 것으로 예측되고 있음

조성에 노력하고 있다.

한편, 인공지능 모델 학습에 있어 학습용 데이터는 모델성능, 신뢰성, 활용 가능성을 좌우하는 핵심 인프라로서 데이터가 부족하거나 편향되거나 라벨링이 부정확하면 성능 저하는 물론, 의료·자율주행처럼 안전과 직결된 분야에서는 심각한 오류로 이어질 수 있다.

이와 관련하여, 미국 등 선도국은 구글(Google)·아마존 웹 서비스(AWS)·마이크로소프트(MS) 등 빅테크 기업을 중심으로 인공지능 학습용 데이터 구축·활용이 활성화되고 있으며, 데이터 가공 시장 등 성장을 견인하고 있다. 특히, 학습용 데이터 가공 플랫폼을 제공하는 기업들이 활발히 성장 중으로, 일부 인공지능 기업은 해당 기업 인수·합병²⁾을 통해 산업 성장에 대비하고 있다.

그리고 우리나라도 인공지능 학습용 데이터 확보를 위한 정부의 투자 확대 등으로 학습용 데이터 구축·가공 관련 기업, 시장 등이 탄생·성장 중이고, 이를 통해 국내 인공지능 서비스 개발에 적합한 다양한 학습용 데이터 자원이 점차 확충되고, 기업의 학습용 데이터 구축 수요도 발생하지만, 아직 많은 인공지능 기업들이 인공지능 도입·운영에 대한 가장 큰 어려움으로 양질의 학습용 데이터 확보에 어려움을 겪고 있다고 호소³⁾하고 있다.⁴⁾

이에 따라 감사원은 인공지능 학습용 데이터의 구축 과정 및 품질관리 등의

2) 미국의 데이터 기업 '스케일 AI'(Scale AI, Inc.)는 로봇·자율차·드론용 이미지에 주석을 다는 소프트웨어 개발을 위해 1,800만 달러의 펀딩을 유치하고, 호주의 데이터 기업 'Appen'(Appen Ltd)은 클라우드소싱으로 학습용 데이터를 생산·제공하는 미국의 AI 데이터 기업을 인수하는 데 3,500억 원을 투자

3) "AI(인공지능)에 대한 기업체 인식 및 실태조사"(2020년, KDI) 결과 인공지능 기업은 인공지능 도입 운영 시 가장 큰 어려움으로 '양질의 데이터 부족(36.1%)'을 꼽았고, "2023 인공지능산업 실태조사"(2024년, 과학기술정보통신부) 결과 인공지능 기업의 70.8%가 '데이터 확보 및 품질 문제'를 인공지능 사업 운영상 느끼는 애로사항으로 동의

4) 이에 정부는 2026. 5. 28. 국무총리 주재로 과학기술정보통신부, 행정안전부, 개인정보보호위원회 등 데이터 관계 부처 장관회의를 개최해, 향후 2~3년이 인공지능 혁신의 골든 타임임을 인식하고 범국가 역량을 결집하여 인공지능 시대에 필요한 데이터 정책을 본격 추진하는 것을 내용으로 하는 "AI 대전환 시대 데이터 정책 추진방향"을 발표

실태를 점검하여 인공지능 기업이 체감할 수 있는 개선 대안을 제시할 목적으로 정부의 인공지능 대응 정책 점검을 위한 시리즈 감사의 세 번째⁵⁾인 이번 감사를 2025년 연간 업무계획에 반영하여 실시하였다.

제2절 감사분야 및 중점

이번 감사는 [표 1]과 같이 과학기술정보통신부 등이 추진하는 인공지능 학습용 데이터 구축사업의 계획 수립부터 데이터 품질관리, 사후관리에 이르는 사업 전 과정을 대상으로 분야별 감사 중점을 도출하였다.

[표 1] 분야별 감사 중점

구축계획 분야	▶ 유사 학습용 데이터 구축 배제를 위한 사전 검토체계가 마련되어 있는지?
품질관리 분야	▶ 지방자치단체 등 공공기관이 생산하는 학습용 데이터에 대한 통일된 품질관리 기준이 작동하는지?
사후관리 분야	▶ 사업수행기관의 폐업 등에 대비한 데이터 유지보수 및 사후관리 방안이 적정한지?

제3절 감사실시 과정 및 접근방법

이번 감사는 계획 수립과정에서 국내외 인공지능 학습용 데이터 구축 현황과 기업 수요 및 관련 정부 대책 수립 현황에 대한 자료 분석이 필요하여 각종 정책 자료와 통계, 국내외 연구보고서, 언론 보도내용 등 서면 자료를 사전 검토하였다.

이후 2025. 9. 15.부터 같은 해 11. 18.까지 총 30일간 3차례⁶⁾ 자료조사를 거쳐 같은 해 11. 26.부터 12. 19.까지 감사 인원 10명을 투입하여 과학기술정보통신부, 행정안전부, 개인정보보호위원회, 한국지능정보사회진흥원 등을 대상으로 총 18일간 실지감사를 하였다.

5) 감사원은 정부의 인공지능 대비실태 점검을 위해 2024년 신뢰성 확보 분야, 2025년 보건·의료분야 개인정보 데이터 제공 및 저작권 관리 분야에 대한 감사를 실시하였음

6) 1차 자료조사: 2025. 9. 15.~9. 26., 2차 자료조사: 2025. 10. 20.~10. 31., 3차 자료조사: 2025. 11. 5.~11. 18.

이와 함께 한국정보통신기술협회⁷⁾를 통해 지방자치단체 및 공공기관이 구축한 인공지능 학습용 데이터의 품질을 검증하는 등 다양한 방식을 활용하였다.⁸⁾

제4절 감사결과 처리

분야별 감사결과와 관련하여 2026. 3. 9. 과학기술정보통신부 인공지능인프라 정책관, 한국지능정보사회진흥원 부원장 등이 참석한 가운데 감사마감회의를 하여, 업무처리 경위 및 향후 처리대책 등 주요 지적사항에 대한 의견을 교환하였다. 이후 감사원에서는 대상기관의 답변서에 제시된 의견 등을 포함하여 지적사항에 대한 내부 검토를 거쳐 2026. 7. 16. 감사위원회회의의 의결로 감사결과를 최종 확정하였다.

7) 「방송통신발전 기본법」 제34조에 따라 정보통신의 표준 제정, 보급 및 정보통신 기술 지원 등 표준화에 관한 업무를 효율적으로 추진하기 위하여 과학기술정보통신부장관의 인가를 받아 설립됨

8) 일부 학습용 데이터의 경우 감사원 자료분석시스템(BARON)을 통해 품질검증을 실시하고, 그 결과를 감사 결과에 활용하였음

제2장 인공지능 학습용 데이터 구축 현황⁹⁾

【 범 례 】

- ◆ 이하 다음의 약칭을 사용하되, ‘조치할 사항’이나 보고서 문맥상 본래의 명칭을 사용하는 것이 이해하기 쉬운 경우에는 본래의 명칭을 사용한다.

[기관명]

- 과학기술정보통신부: 과기정통부
- 문화체육관광부: 문체부
- 중소벤처기업부: 중기부
- 행정안전부: 행안부
- 식품의약품안전처: 식약처
- 개인정보보호위원회: 개보위
- 공정거래위원회: 공정위
- 한국정보통신기술협회: 기술협회
- 한국지능정보사회진흥원: 지능정보사회원

[법률명]

- 「공공데이터의 제공 및 이용 활성화에 관한 법률」: 공공데이터법
- 「데이터 산업진흥 및 이용촉진에 관한 기본법」: 데이터산업법
- 「방송통신발전 기본법」: 방송통신발전법
- 「소프트웨어 진흥법」: 소프트웨어법
- 「인공지능 발전과 신뢰 기반 조성 등에 관한 기본법」: 인공지능기본법
- 「지능정보화 기본법」: 지능정보화법

[주요 용어 설명]

- AI(Artificial Intelligence): 인공지능

제1절 인공지능 관련 정책 추진 개요

최근 오픈AI, 메타(Meta) 등 글로벌 빅테크 기업들은 인공지능 학습모델 기술 경쟁 심화에 대응하고자 대규모 데이터 확보에 주력하고 있다. 이들 기업은 고품질 인공지능 학습용 데이터 선점을 위해 인공지능 데이터 구축 전문기업을 인수하는

9) 이 부분은 감사결과 지적된 문제점의 종합적 이해를 돕기 위해 감사대상 업무의 현황을 기술한 것으로, 각종 연구 보고서와 감사대상기관이 제출한 자료 등을 바탕으로 작성되었으며 현장조사 등 감사의 방법으로 검증한 내용이 아님

등 데이터 자산 확보 경쟁을 가속화하여 글로벌 시장 주도권을 강화하는 추세다.

우리나라도 2019년 12월 최초의 인공지능 종합대책인 “인공지능 국가전략”을 수립한 이후, 인공지능 학습용 데이터 구축·활용을 위해 [표 2]와 같이 단계별 정책을 추진해 왔다. 특히, 2020년 7월 디지털 전환 가속화에 대비하기 위해 “『한국판 뉴딜』 종합계획”¹⁰⁾을 수립하여 대표 프로젝트로 같은 해 9월부터 ‘데이터 댐’ 구축을 본격화하였고, 2022년 1월 “인공지능(AI) 학습용 데이터 구축·활용 고도화 방안”을 마련하여 인공지능 학습용 데이터 구축·공개에 2025년까지 약 2.5조 원의 대규모 투자를 계획하는 등 지속적으로 제기되는 양질의 데이터 부족 문제 해소와 체계적 학습용 데이터 자원 확보 및 활용에 역량을 집중하고 있다.

[표 2] 인공지능 관련 주요 정책 수립 현황

구분	주요 내용
인공지능 국가전략 (2019년 12월)	■ AI 강국 도약을 위해 ① AI 생태계 구축, ② AI 활용 확산, ③ 사람 중심의 AI 구현 등 3대 분야에 걸쳐 9대 전략과 100대 실행과제를 수립
「한국판 뉴딜」 종합계획 (2020년 7월)	■ 디지털 뉴딜 관련 ① D.N.A.(Data, Network, AI) 생태계 강화, ② 교육인프라 디지털 전환, ③ 비대면 산업 육성, ④ SOC 디지털화 등 4개 분야 12개 과제 수립
인공지능(AI) 학습용 데이터 구축·활용 고도화 방안 (2022년 1월)	■ ① 데이터 구축·개방 로드맵 수립·이행, ② 구축 데이터의 활용성과 가치 증진 지원
인공지능 일상화 및 산업 고도화 계획 (2023년 1월)	■ ① 전 국민 AI 일상화, ② 공공·산업 전면 융합, ③ AI 기업 성장, ④ AI 글로벌화, ⑤ AI 기술 초격차 등 인공지능 10대 핵심 프로젝트 선정
초거대 AI 경쟁력 강화 방안 (2023년 4월)	■ ① 초거대 AI 기술·산업 인프라 확충, ② 초거대 AI 혁신 생태계 조성, ③ 범국가 AI 혁신 제도·문화 정착 등 3대 전략과 9개 추진과제 수립
새로운 디지털 질서 정립 추진계획 (2024년 5월)	■ 법·제도 개선, 연구개발 및 시범사업 추진 등 20대 정책과제를 제시
이재명 정부 123대 국정과제 (2025년 9월)	■ AI 3대 강국 도약 관련 ① AI 3대 강국 도약을 위한 AI고속도로 구축, ② 세계에서 AI를 가장 잘 쓰는 나라 구현, ③ 초격차 AI 선도기술·인재 확보 등 6개 과제 확정
대한민국 인공지능행동계획 [인공지능 기본계획(2026~2028)] (2026년 2월)	■ ‘AI 3대 강국 도약’ 비전 달성을 위한 ① AI 혁신 생태계 조성, ② 범국가 AI 기반 대전환, ③ 글로벌 AI 기본사회 기여 등 3대 정책축과, 이를 뒷받침하는 AI고속도로 구축 등 12대 전략분야와 AI 데이터 공유 생태계 활성화 등 99개 실행과제 확정

자료: 과기정통부 등 제출자료 재구성

10) 디지털 뉴딜, 그린 뉴딜, 안전망 강화 등 3대 정책방향을 제시하고 있으며, 그중 디지털 뉴딜은 2025년까지 AI 학습용 데이터 1,300종 구축 등을 목표로 하는 D.N.A.(Data, Network, AI) 생태계 강화, 교육인프라 디지털 전환, 비대면 산업 육성, SOC 디지털화를 주요 내용으로 함

제2절 인공지능 학습용 데이터 현황

1. 개념

인공지능기본법 제2조에 따르면 ‘인공지능’이란 학습, 추론, 지각, 판단, 언어의 이해 등 인간이 가진 지적 능력을 전자적 방법으로 구현한 것을 의미하고, ‘학습용 데이터’란 인공지능의 개발과 활용 등에 사용되는 데이터를 의미하는데, 이는 인공지능이 지능을 갖추는 데 필요한 핵심 자원으로, 양질의 데이터를 풍부하고 다양하게 학습할수록 인공지능의 성능과 정확도는 향상된다.

2. 일반 데이터와 인공지능 학습용 데이터 비교

[표 3]과 같이 일반 데이터는 통계나 기록 등 일반적인 목적에 활용되는 수집된 원본 상태의 데이터로 중복된 내용, 불필요한 정보 등이 섞여 있어 인공지능이 직접 학습하기에는 한계가 있는 반면, 인공지능 학습용 데이터는 별도의 정제 공정을 통해 학습을 방해하는 불순물을 제거하여 편향·노이즈를 최소화한 가공데이터¹¹⁾로 모델 학습에 최적화되어 있다.

[표 3] 일반 데이터와 인공지능 학습용 데이터의 차이

구분	일반 데이터	인공지능 학습용 데이터
사용 목적	분석, 보고, 운영, 저장	인공지능 모델 학습 및 추론
사용 주체	사람(분석가 등)	기계(인공지능 모델)
활용 방식	사람이 읽고 해석	AI가 자동으로 학습·판단
가공 수준	원시데이터 또는 단순 정제	정제, 라벨링 ^{주)} , 증강 등
재사용성	일회성, 기록 중심	반복 학습, 재훈련 가능
데이터 구조	정형, 비정형 혼재	입력-출력 쌍 등으로 구조화
데이터 형식 예시	일회성, 기록 중심	문서-요약 쌍, 이미지-라벨 쌍 등

주: 라벨링은 인공지능이 학습할 수 있도록 데이터에 정답표를 붙이는 작업임

자료: 지능정보사회원, 「AI 학습데이터 구축 안내서」, 2025년 10월

11) 2025년 2월 「AI 데이터 품질관리 가이드라인 v3.5」로 개정 시 종전의 용어 ‘라벨링데이터’가 ‘가공데이터’로 변경됨


3. 인공지능 학습용 데이터 공개 방식

인공지능 기업이 공공분야의 데이터를 인공지능 학습에 활용하는 방식은 ① 중앙행정기관·지방자치단체·공공기관 등이 보유한 공공데이터¹²⁾를 제공받아 인공지능 학습에 적합한 형태로 직접 가공하는 방식과, ② 인공지능 학습용으로 정제·가공되어 공개된 데이터를 활용하는 방식으로 구분된다.

전자의 경우 개별 공공기관의 포털이나 행안부의 공공데이터포털을 통해 데이터를 제공받을 수 있는데, 공공데이터포털에는 2026년 5월 기준으로 107,511건의 데이터가 등록되어 있다. 그러나 공공데이터는 대부분¹³⁾ 인공지능 학습을 전제로 구축된 것이 아니므로, 실제 인공지능 학습에 활용하기 위해서는 데이터 정제, 라벨링, 형식 변환 등 별도의 가공 절차가 필요하다.

반면, 정제·가공된 인공지능 학습용 데이터를 제공하는 방식의 경우, 소관 부처인 과기정통부가 전문적인 데이터 구축·관리를 위해 지능정보화법 제12조에 따라 설립된 지능정보사회원을 전담기관으로 지정하여 관련 사업을 추진하고 있으며, 이를 통해 구축된 데이터는 [그림 1]과 같이 AI Hub(www.aihub.or.kr)를 통해 대외에 공개된다.

[그림 1] AI Hub를 통한 인공지능 학습용 데이터 공개 구조



자료: 과기정통부 등 관계부처 합동, “인공지능(AI) 학습용 데이터 구축·활용 고도화 방안”, 2022년 1월

12) 공공데이터법 제2조 제2호에 따르면 데이터베이스, 전자화된 파일 등 공공기관이 법령 등에서 정하는 목적을 위하여 생성 또는 취득하여 관리하고 있는 데이터로 규정

13) 일반 데이터와 인공지능 학습용 데이터를 별도로 구분하지 않고 제공하고 있어 정확한 규모를 산출하기 어려움

가. 인공지능 학습용 데이터 공개 현황

과기정통부는 지능정보화법 제42조, “인공지능 국가전략”(2019년 12월) 및 “『한국판 뉴딜』 종합계획”(2020년 7월) 등에 따라 2025년까지 AI 학습용 데이터 1,300종의 구축 계획을 발표하였고, [표 4]와 같이 2017년부터 2024년까지 총 1조 6,328억 원의 예산을 투입하여 AI 학습용 데이터세트 총 903종을 구축하였으며, 2025년 11월 기준으로 908종을 AI Hub에 공개 중이다.

[표 4] 인공지능 학습용 데이터 구축 사업 추진 현황(2017~2024년)

(단위: 종, 억 원)

구축 연도	2017~2020년	2021년	2022년	2023년	2024년	총계
학습용 데이터 수	191	190	310	142	70	903
총사업비	3,640	3,705	5,797	2,628	558	16,328

주: 903종 중 12종은 구축 후 각각 2종으로 분리·공개하여 총 915종을 공개하였으나 그중 7종은 데이터 재검증을 위해 공개를 중단 중이며 2025년 11월 기준 908종을 공개 중

자료: 과기정통부 및 지능정보사회원 제출자료 재구성

나. 인공지능 학습용 데이터 통합제공체계

과기정통부는 2025년 3월부터 민간·공공에서 개별적으로 구축해서 제공하고 있는 학습용 데이터의 소재 정보를 확인할 수 있도록 ‘원-윈도우 포털’을 구축하여 시범 운영 중이며, 금융혁신 빅데이터 플랫폼, AI Hub, 공공데이터포털을 비롯한 국내 42개 포털(2025년 10월 기준)의 데이터 소재 정보를 제공하여 필요한 데이터를 빠르게 검색하고 취득할 수 있도록 지원하고 있다.

또한, 과기정통부는 인공지능기본법 제15조 제4항 및 같은 법 시행령 제13조와 국정과제 20 ‘AI 3대 강국 도약을 위한 AI고속도로 구축’의 하위과제인 ‘국가 전체 공공·민간 인공지능 학습용 데이터 통합플랫폼 구축’ 목표에 따라 공공·민간에 산재해 있는 인공지능 학습용 데이터를 모아 한곳에서 통합 제공¹⁴⁾하는

14) 원-윈도우 포털은 데이터의 소재 정보(특정 데이터를 어떤 포털에서 제공 중인지)만을 제공하나, AI 학습용 데이터 통합제공체계는 데이터 자체를 제공한다는 차이가 있음

‘국가 AI 데이터 집적 클러스터’(통합제공시스템) 구축을 계획¹⁵⁾하고 있으며, 2025년 12월 현재 지능정보사회원을 통해 인공지능 학습용 데이터 통합제공체계 구축 정보화전략계획(ISP) 수립을 진행하고 있다.

제3절 인공지능 학습용 데이터 구축 절차

1. 인공지능 학습 방식

인공지능은 사람처럼 설명을 듣거나 직관으로 배우지 않고, 수많은 예시(데이터)를 통해 규칙과 패턴을 찾아 스스로 문제를 해결할 수 있도록 훈련한다.

인공지능 학습 방식은 [표 5]와 같이 지도학습·비지도학습·준지도학습·강화 학습 등으로 구분할 수 있는데, 이러한 인공지능 학습 방법에 따라 학습용 데이터는 문제와 정답을 함께 담은 데이터, 일부만 알려주고 스스로 추론하게 하는 데이터 등 다양한 형태로 구성할 수 있고, 이를 인공지능 학습 목적에 맞게 적절히 정제하고 가공할 때 인공지능 성능은 폭발적으로 향상된다.

[표 5] 인공지능 학습 방식

구분	설명	필요한 데이터 형태
지도학습	• 입력에 대한 정답이 있는 데이터를 통해 학습	문제(입력)-정답(출력) 쌍
비지도학습	• 정답 없이 데이터 자체의 패턴을 스스로 검색	입력만 존재
준지도학습	• 일부 데이터에만 정답이 있고, 나머지는 정답이 없이 학습	일부 문제-정답, 나머지는 입력만 존재
강화학습	• 행동에 대한 보상을 통해 AI가 더 나은 행동을 학습	상태-행동-보상

자료: 지능정보사회원, 「AI 학습데이터 구축 안내서」, 2025년 10월

2. 인공지능 학습용 데이터 구축 절차

인공지능 학습용 데이터 구축 과정은 구축계획 수립 후 [표 6]과 같이 ① 데이터 획득·수집, ② 데이터 정제, ③ 데이터 가공, ④ 데이터 학습 단계 순서로 진행되며, 데이터 품질에 문제가 발견되거나 모델 성능 향상을 위해 데이터 보완

15) 2026년 12월 중 시범 운영 개시 예정

또는 가공 재검토가 필요한 경우 단계의 일부를 반복적으로 수행하며 개선한다.

[표 6] 인공지능 학습용 데이터 구축 절차

단계	① 획득·수집 단계	② 정제 단계	③ 가공 단계	④ 학습 단계
검수 기준	공개·배포 가능 여부	데이터 정합성·일관성	라벨 정확성	모델 학습 정합성
	획득 가능 데이터 수량	오류·노이즈 제거	과업 적합성	데이터 분할 적정성
	라이선스 적합성	중복 제거	지침 준수 여부	성능 기여도
	법적 권리 침해 여부	비식별화 적정성	편향 최소화	안전성 평가
검수 내용	데이터 권원 조사	품질지표 산출	라벨 확인	성능 평가 지표
	원시데이터 품질검사	형식·포맷 통일	입력·출력 매칭 검토	유해·개인정보 필터링 점검

자료: 지능정보사회원, 「AI 학습데이터 구축 안내서」, 2025년 10월

3. 인공지능 학습용 데이터 주요 유형

인공지능 학습용 데이터의 유형은 [표 7]과 같이 텍스트, 이미지, 영상, 오디오 등 학습 대상이 되는 데이터 형태에 따라 구분된다.


[표 7] 인공지능 학습용 데이터 주요 유형

구분	텍스트 데이터	이미지 데이터	영상 데이터	오디오 데이터	합성 데이터
원천데이터	문서, 기사, 대화 등의 원문 텍스트 데이터	직접 촬영 또는 디지털 장치로 수집한 정적 시각 데이터	시간의 흐름에 따라 연속적으로 변화하는 동적 시각 데이터	녹음이나 녹취 등을 통해 획득된 자연어·비자연어 소리 데이터	실제 데이터의 특징을 반영해 유사한 결과를 얻을 수 있도록 새롭게 생성한 데이터
가공데이터	주제·의도 분류, 개체명·용어 주석 등 텍스트의 의미 구조를 인공지능 학습에 맞게 가공	객체 검출, 공간위치 정보 등을 통해 사람이 이해하는 시각정보를 인공지능 학습에 맞게 가공	객체의 위치, 경로, 행동 특성을 주석화 하고 프레임 간 일관성을 유지하도록 구조화하여 사람이 인식하는 동적정보를 인공지능 학습에 맞게 가공	화자의 감정·의도 라벨링, 억양·강세 등 음향적 특성을 반영하여 음성신호를 인공지능 학습에 맞게 가공	합성 데이터 생성 모델로 합성 데이터를 생성한 뒤, 개인식별자 및 이상값 노출 위험을 점검하고 다양성·분포성을 검증하여 구축

자료: 지능정보사회원, 「AI 학습데이터 구축 안내서」, 2025년 10월

그리고 인공지능 학습용 데이터는 텍스트, 이미지, 영상, 오디오(음성) 등의 원천데이터와 [그림 2]와 같이 인공지능 모델이 정확하게 인식하고 학습이 가능하도록 가공(라벨링)된 데이터로 구성된다.

[그림 2] 인공지능 학습을 위한 데이터 가공(예시)

음성·텍스트(한국인 대화음성)	이미지(질환 이미지)	영상(CCTV 이상행동분석)
		
음성파일을 텍스트로 변환하여 성별, 발화주제 등 속성값 부여	병변 진단·판독, 환부 영역표시·주석 등 정보 기입	영상 속 객체 구분과 이상행동 여부 파악, 동작 등 설명·표기

자료: 과기정통부 등 관계부처 합동, “인공지능(AI) 학습용 데이터 구축·활용 고도화 방안”, 2022년 1월

제4절 인공지능 학습용 데이터 품질관리

1. 인공지능 학습용 데이터의 품질관리 원칙

인공지능 학습용 데이터의 품질관리¹⁶⁾를 위해서는 데이터가 갖는 특성을 파악하여 이를 기반으로 데이터 품질 확보에 적합한 품질관리 체계를 확보하는 것이 중요하다. 고품질의 인공지능 학습용 데이터를 확보하기 위해서는 원시·원천·가공데이터¹⁷⁾ 등 공정별 데이터 자체의 품질은 물론, 이를 사용자 요구에 맞춰 지속적으로 유지·향상시킬 수 있는 품질관리 체계가 필요하다.

인공지능 학습용 데이터의 품질관리 원칙은 [표 8]과 같이 데이터 측면에서는 라벨링 정보의 정확성과 유효성이 확보되어야 하고, 품질관리 측면에서는 데이터 전 생애주기(준비·계획, 구축, 운영·활용) 동안 상시적이고 지속적인 품질 개선이 가능해야 한다.

16) ‘인공지능 학습용 데이터의 품질’이란 “인공지능 학습에 필요한 데이터의 적합성, 정확성, 유효성 등을 확보하여 사용자에게 유용한 가치를 줄 수 있는 수준”을 의미하고, ‘품질관리’란 이러한 데이터의 품질을 확보하는 데 필요한 조직, 절차, 품질기준, 품질관리 방법이나 활동 등을 정의하여 점검하고 조치하는 일련의 활동

17) ① 원시데이터: 클라우드 소싱 또는 전문인력을 통해 직접 생산하거나, 기존에 운영 중인 내부 시스템, 외부 자료 등에 이미 존재하는 데이터
 ② 원천데이터: 획득한 원시데이터에 대해 인공지능 학습에 필요한 형식, 크기 등을 조정하고 중복 제거 및 개인정보 비식별화 처리 등 정제과정을 통해 얻은 데이터
 ③ 가공데이터: 원천데이터에 인공지능 학습 목적에 맞는 정답(Ground Truth)과 주석 등 부가정보를 부여하여, 인공지능 학습모델에 활용할 수 있는 ‘학습데이터’로 전환하는 과정에 있는 데이터

[표 8] 인공지능 학습용 데이터 품질관리 원칙

구분	원칙
데이터 측면	■ 인공지능 학습용 데이터를 학습하는 데 필요한 요구사항을 충족해야 함 ■ 법률적 제약 없이 누구나 활용 가능해야 함 ■ 학습 목적에 부합하도록 획득·수집되어야 하며, 데이터는 중복 없이 원하는 목적에 따라 정제되어야 함 ■ 인공지능 학습용 데이터에 부여하는 참값(Ground Truth) 등 라벨링 정보의 정확성이 확보되어야 함 ■ 인공지능 학습모델을 통해 목표로 하는 유효성이 확보되어야 함
품질관리 측면	■ 인공지능 학습용 데이터 전 생애주기의 품질을 보장해야 함 ■ 상시적이고 지속적인 인공지능 학습용 데이터 품질 개선이 가능해야 함 ■ 데이터 품질관리를 위한 조직을 구성하고, 정해진 역할과 책임에 따라 수행해야 함 ■ 조직의 품질관리 역량을 확보하도록 품질관리 교육 등 지원체계를 확보해야 함

자료: 지능정보사회원, 「AI 데이터 품질관리 가이드라인 v3.5」, 2025년 2월

2. 품질지표

인공지능 학습용 데이터의 품질지표는 데이터가 구축 목적에 부합하는 품질 수준을 갖추었는지 측정하기 위한 기준으로 [표 9]와 같이 유용성, 다양성, 구문 정확성, 유효성 등 9가지 지표로 구성된다.

[표 9] 인공지능 학습용 데이터 품질지표

구분	품질지표	구분	품질지표
구축 공정 적정성	① 준비성	가공데이터 정확성	⑥ 구문 정확성
	② 완전성		⑦ 의미 정확성
	③ 유용성		
데이터 적합성	④ 기준 적합성	학습모델 적합성	⑧ 알고리즘 적정성
	⑤ 다양성		⑨ 유효성

자료: 지능정보사회원, 「AI 데이터 품질관리 가이드라인 v3.5」, 2025년 2월

3. 품질검증 체계

과기정통부는 데이터산업법 제20조 제1항 및 제3항에 따라 데이터의 품질 향상을 위하여 행안부와 협의하여 [표 10]과 같이 ① 데이터의 내용(데이터값의 입력규칙·형식을 기준으로 정형·비정형 데이터값의 오류 여부 심사), ② 데이터 관리


체계 등을 심사하는 등 데이터 품질인증을 실시하기 위해 기술협회 등¹⁸⁾을 인증기관으로 지정하고 있다.

[표 10] 데이터 품질인증기관 지정 및 품질인증 수행 절차

구분	데이터 품질인증기관 지정	데이터 품질인증 수행
주체	과기정통부	인증기관
절차	인증기관 지정·공고 → 인증기관 심의·지정	인증 신청·접수 → 인증심사 → 인증서 발급·관리

지능정보사회원은 데이터 품질을 객관적으로 확보하기 위해 [그림 3]과 같이 먼저 인공지능 학습용 데이터를 구축하는 사업수행기관으로 하여금 품질자가점검을 하도록 한 후, 학습용 데이터 납품 전 최종적으로 품질지표 기준을 충족하는지 기술협회 등 외부 품질검증기관을 통한 제3자 품질검증 체계¹⁹⁾를 운영하고 있다.

[그림 3] 인공지능 학습용 데이터 품질검증 프로세스



자료: 지능정보사회원 제출자료 재구성

18) 데이터산업법 제20조에 의거한 데이터 품질인증기관 지정 현황(2023. 7. 6.): ① 기술협회(<https://cs.tta.or.kr/>), ② , ③ 
 19) 제3자 품질검증은 품질지표 기준서를 기준으로 기술협회 등이 데이터의 품질 목표 달성 여부를 측정한 후 품질검증결과서를 지능정보사회원과 사업수행기관에 발급하는 방식으로 진행

제3장 분야별 감사결과

제1절 감사결과 총괄

정부는 고품질의 인공지능 학습용 데이터를 구축하여 인공지능 강국 도약 및 인공지능 주권을 확보하고자 2017년부터 2024년까지 1조 6,328억 원의 예산을 투입하여 총 908종의 데이터를 구축하고, AI Hub에 공개하는 등 인공지능 확산 생태계를 조성하기 위해 노력하고 있으나, 이번 감사에서 ① 학습용 데이터 구축계획, ② 학습용 데이터 품질관리, ③ 학습용 데이터 사후관리 등 3개 분야로 나누어 정부의 인공지능 학습용 데이터 구축사업 추진 실태를 점검한 결과 [표 11]과 같이 총 3건의 문제점이 확인됨에 따라, 이에 대한 개선방안을 마련할 수 있도록 감사결과를 통보하였다.

[표 11] 분야별·기관별 감사결과 통보 현황

(단위: 건)

구분	계	과기정통부	지능정보사회원
합계	3	2	1
학습용 데이터 구축계획 분야	1	1	-
학습용 데이터 품질관리 분야	1	1	-
학습용 데이터 사후관리 분야	1	-	1

한편, 이러한 문제점은 과기정통부가 지능정보화법 제42조 및 인공지능기본법 제15조에 따라 행안부 등과 협의하여 개별 공공기관의 학습용 데이터 구축 및 품질관리 등의 시책을 수립하여야 하는데도 그동안 AI Hub를 통해 공개하는 학습용 데이터의 구축 및 품질관리에만 노력을 기울인 데 따른 것으로 보인다.

또한 과기정통부는 개별 공공기관이 구축한 후 개별포털에 공개하는 학습용 데이터에 대해서는 그 실태를 파악하지 못하고 있어²⁰⁾ 사전 검토체계 및 공통된

20) 과기정통부는 2026. 4. 10. 인공지능 학습용 데이터 보유 현황을 전 부처 대상으로 첫 전수조사를 실시하여 인공지능 활용이 가능한 고품질 데이터 기반을 마련하기 위해 노력할 것이라고 보도자료 배포

품질관리 기준을 마련하지 않고 있는 등 총괄 조정 기능이 미흡한 데도 원인이 있는 것으로 판단된다.

주요 감사결과를 요약하면 다음과 같다.

분야	주요 감사결과
학습용 데이터 구축계획 분야	■ 개별 공공기관에서 학습용 데이터를 새로 구축할 때 기존 데이터와의 유사성 및 대체 활용 가능성을 사전에 검토할 수 있는 기준과 절차 등이 없어 개별 공공기관이 유사한 데이터를 새로 구축하여 예산 집행의 효율성을 저해 [기존 구축 학습용 데이터를 확인하지 않고 새로 구축한 사례] - 과기정통부가 2020년에 생활폐기물 학습용 데이터(학습 대상 128종류, 이미지 150,000장)를 먼저 구축하여 AI Hub에 공개하였는데도 대전광역시 서구는 2025년에 생활폐기물 데이터를 별도로 구축하여 개별포털에 공개 → 점검결과, 대전광역시 서구가 구축한 학습 대상 45종류(이미지 9,000장) 중 26종류[이미지 5,200장(57.8%)]가 유사 [기관 간 구축 계획 사전 미공유로 같은 연도에 유사한 학습용 데이터를 구축한 사례] - 구강 학습용 데이터의 경우 과기정통부(5종류, 이미지 145,140장)와 개보위(2종류, 이미지 1,000장)가 2023년에 동시에 데이터를 구축하여 각각 AI Hub와 개별포털에 공개 → 점검결과, 개보위의 학습 대상 2종류[이미지 1,000장(100%)]가 모두 과기정통부와 유사 ⇒ 과기정통부에 행안부와 협의하여 개별 공공기관이 학습용 데이터를 구축할 때 이미 구축된 학습용 데이터의 대체 활용 가능성을 사전 검토하고, 개별 공공기관의 데이터 구축 계획을 사전에 공유·조정하는 등 사전 검토체계를 마련하는 방안을 강구하도록 통보
학습용 데이터 품질관리 분야	■ 과기정통부에서 구축·공개한 인공지능 학습용 데이터는 품질관리 가이드라인 등에 따라 품질 자가점검 및 제3자 품질검증을 하는 반면, 개별 공공기관은 통일된 품질관리 기준이 없어 구축·공개된 인공지능 데이터의 품질을 측정할 수 없을 뿐만 아니라 서울특별시 및 한국도로공사의 경우 왜곡된 학습용 데이터가 수정·보완되지 않은 채 공개되고 있는 사례 확인 [라벨링 정보가 누락·구축된 학습용 데이터 공개 사례] - 한국도로공사가 2025년 구축한 ‘도로주행 CCTV 학습데이터셋’은 이미지(원천데이터) 2,680장에 대한 바운딩 박스 위치 좌표 정보가 누락된 채 어노테이션 파일(가공데이터)이 구축돼 인공지능 모델이 학습할 수 없는데도 그대로 공개 중 [품목명(JSON 파일)과 이미지가 불일치하게 구축된 학습용 데이터 공개 사례] - 서울특별시가 2020년 구축한 ‘대형폐기물 학습데이터’는 이미지(원천데이터) 총 2,303장 중 538장(23.4%)이 JSON 파일과 일치하지 않는데도 수정·보완 없이 그대로 공개 중 ⇒ 과기정통부에 행안부와 협의하여 개별 공공기관이 학습용 데이터를 구축할 때 공통 적용하는 품질관리 기준 등을 마련하는 방안을 강구하도록 통보

학습용 데이터
사후관리 분야

- 지능정보사회원은 학습용 데이터 수정 등의 민원을 접수하고, 왜곡된 학습용 데이터를 확인하고도 사업수행기관 폐업 등을 사유로 학습용 데이터 수정이 불가능한 것으로 민원을 종결 처리하고 있어 왜곡된 학습용 데이터가 계속해서 외부에 공개되고 있는 실정
- ⇒ 지능정보사회원에 폐업한 사업수행기관이 구축한 왜곡된 정보를 즉시 수정할 수 있도록 제3자 유지보수 체계를 구축하는 등 실효성 있는 사후관리 방안을 마련하도록 통보

제2절 학습용 데이터 구축계획 분야

1 학습용 데이터 구축사업 사전 검토체계 도입 필요

1. 업무 개요

과기정통부는 지능정보화법 제42조 및 인공지능기본법 제15조, “인공지능 국가전략”(2019년 12월)과 “인공지능(AI) 학습용 데이터 구축·활용 고도화 방안”(2022년 1월) 등에 따라 인공지능 학습용 데이터를 구축하고 인공지능 학습용 데이터 제공 플랫폼인 AI Hub²¹⁾를 통해 공개하고 있다.

인공지능 학습용 데이터는 2017년부터 민간 수요를 기반으로 구축해왔으며, [표 12]와 같이 2025년 11월 기준 14개 분야(한국어, 헬스케어, 교통물류 등) 908종²²⁾의 학습용 데이터를 공개 중이다.

[표 12] 인공지능 학습용 데이터 공개 현황

공개 시스템	분야	데이터 수	관계 법령
AI Hub	14개 분야	908종	인공지능기본법 제15조

자료: 과기정통부 및 지능정보사회원 제출자료 재구성

한편, 과기정통부가 AI Hub를 통해 공개 중인 인공지능 학습용 데이터와 별도로 중기부, 서울특별시, 한국도로공사 등 총 26개 공공기관²³⁾에서도 개별 포털(예: 서울열린데이터광장), 공공데이터포털 등을 통해 2025년 11월 말 기준 313종의 인공지능 학습용 데이터를 구축·공개하고 있다.

이와 관련, 행안부는 2025년부터 ‘AI 친화·고가치 데이터 개방 노력 지표’를

21) 지능정보화법 제12조에 따라 지능정보사회원에 위탁하여 AI Hub를 운영·관리

22) 학습용 데이터 1종은 원천데이터 수백~수십만 건, 가공데이터 수백~수십만 건으로 이루어진 데이터셋트를 말함

23) 공공데이터법 제2조 제1호에 따라 ‘공공기관’이란 국가기관, 지방자치단체 및 지능정보화법 제2조 제16호에 따른 공공기관을 말함

‘공공데이터 제공 운영실태 평가’²⁴⁾ 항목에 추가하였고, 2026년 ‘AI·고가치 공공데이터 TOP 100 개방’의 세부과제인 ‘AI 학습용 공공데이터 가공사업’을 통해 인공지능 활용 가능성 및 사회·경제적 파급효과가 크고 가치가 높은 공공데이터(TOP 100)를 인공지능 학습용 데이터로 가공하여 공개할 예정이라는 점을 고려할 때 앞으로 개별 공공기관의 인공지능 학습용 데이터 구축·공개는 더욱 활발해질 것으로 전망된다.

2. 감사접근 방법

가. 주요 해외 사례

미국 등 해외 주요국은 데이터의 목록·소재 정보·메타데이터²⁵⁾를 제공하는 데에서 더 나아가 공공데이터 재사용 체계를 운영하고 있다. 공공데이터 재사용 체계를 통해 공공기관은 신규 인공지능 학습용 데이터를 구축하기에 앞서 기존에 구축된 학습용 데이터의 재사용 가능성을 검토하고 필요에 따라 신규 데이터를 구축하고 있다.

예를 들어, 미국은 「Federal Data Strategy」²⁶⁾의 원칙 5(Harness Existing Data)에서 “우선 기존 데이터를 재사용하고, 필요한 경우에만 추가 데이터를 확보(reuse data if possible and acquire additional data if needed)”하도록 하고 있으며, 하위 전략인 “Federal Data Strategy: 2021 action plan”에서 기관별 데이터 목록과 소재 정보를 제공하여 데이터의 존재 여부, 접근 경로, 메타데이터 등을 확인할 수 있도록 하고 있다.

24) 공공데이터법 제9조에 따라 공공기관을 대상으로 실시되며, 2025년 기준 평가대상기관은 684개

25) 메타데이터란 다른 데이터의 내용, 구조, 출처 등을 설명하는 부가정보로, 데이터를 어떻게 활용해야 할지 알려주는 데이터임

26) 미국의 「Federal Data Strategy」는 인공지능 학습용 데이터 전용 전략은 아니나, 미국 연방정부 전체의 데이터 관리·활용 전략(데이터 거버넌스 원칙)으로 인공지능 학습용 데이터에도 적용 가능함

그리고 영국은 “Code of Practice for Statistics”(2025년)에서 새로운 데이터를 수집하기 전 기존 데이터의 적합성과 이용 가능성을 확인하도록 하고 있으며, “Guidelines and best practices for making government datasets ready for AI”(2026년 1월)에 따르면 인공지능 학습용 데이터는 데이터의 생성 맥락, 상호운용성, 인공지능 활용 적합성 등을 종합적으로 고려하여 정의된다고 설명하고 있다.

나. 국내 인공지능 학습용 데이터 통합제공시스템의 한계

과기정통부는 2025년 3월부터 민간·공공에서 개별적으로 구축해서 공개하고 있는 학습용 데이터의 소재 정보를 확인할 수 있도록 ‘원-윈도우 포털’을 구축하여 시범 운영 중이며, 금융혁신 빅데이터 플랫폼, AI Hub, 공공데이터포털을 비롯한 국내 42개 포털(2025년 10월 기준)의 학습용 데이터 소재 정보를 제공하여 필요한 학습용 데이터를 빠르게 검색하고 취득할 수 있도록 지원하고 있다.

하지만, 원-윈도우 포털 및 AI Hub 등은 데이터 검색 기능만 갖추고 있을 뿐, 개별 공공기관이 인공지능 학습용 데이터를 신규로 구축하기에 앞서 구축 목적, 학습 대상 등이 유사한 기존 학습용 데이터를 찾아 대체 활용할 수 있는지, 개별 공공기관이 필요한 학습용 데이터를 신규로 구축할 필요가 있는지 등을 사전에 비교·판단하도록 하는 기준 및 절차 등 사전 검토체계는 없는 실정이다.²⁷⁾

또한, 과기정통부는 인공지능기본법 제15조 제4항 및 같은 법 시행령 제13조와 국정과제 20 ‘AI 3대 강국 도약을 위한 AI고속도로 구축’의 하위과제인 ‘국가 전체 공공·민간 인공지능 학습용 데이터 통합플랫폼 구축 목표’에 따라 공공·민간에 산재해 있는 인공지능 학습용 데이터를 모아 한곳에서 통합 제공²⁸⁾하는 ‘국가

27) 인공지능기본법 제15조 제4항 및 같은 법 시행령 제13조에 따르면 통합제공시스템의 학습용 데이터 검색·연계·정보 제공 등의 기능만을 열거적으로 규정하고 있고 별도 기능은 과기정통부장관이 데이터 구축사업의 효율적 수행을 위하여 필요하다고 인정하는 경우 수행할 수 있도록 규정

28) 원-윈도우 포털은 데이터의 소재 정보(특정 데이터를 어떤 포털에서 제공 중인지)만을 제공하나, 인공지능 학습용 데이터 통합제공체계는 데이터 자체를 제공한다는 차이가 있음

AI 데이터 집적 클러스터’(이하 “통합제공체계”라 한다) 구축을 계획²⁹⁾하고 있다.

이에, 지능정보사회원은 2025. 9. 26. 「AI 학습용 데이터 통합제공체계 구축 방안」을 마련하였는데 [표 13]과 같이 인공지능 학습용 데이터 통합제공체계 추진과제 및 세부 추진과제를 살펴보면 기존에 구축된 인공지능 학습용 데이터를 통합·연계하고 수요자에게 제공하는 데에 중점을 두고 있고, 개별 공공기관이 신규 데이터를 구축할 때 기존의 데이터를 활용할 수 있는지 사전에 검토하는 기준 및 절차에 관한 내용은 없어 이미 구축되어 공개 중인 인공지능 학습용 데이터가 개별 공공기관별로 다시 구축되지 않도록 관리·통제하는 역할에는 여전히 한계를 노출하고 있다.

[표 13] 인공지능 학습용 데이터 통합제공체계 추진과제

구분	추진과제	세부 추진과제
통합플랫폼 확보	■ AI 학습용 데이터 집적 클러스터 확보	① AI 집적 클러스터 인프라 구축 ② AI 학습용 데이터 지능형 검색 ③ AI 학습용 데이터 수집 및 클러스터 등록 ④ 원시데이터 수집·축적 체계 구축
	■ AI 학습용 데이터 파운드리 확보	① AI 학습용 데이터 파운드리 구축 ② 파운드리 활용 톨 개발 및 확보 ③ 기업 참여 방안 및 체계 마련
	■ AI 학습용 데이터 통합 제공 플랫폼	① AI 학습을 위한 컴퓨팅 환경 구축 ② AI 모델 데이터 리더보드 구축 ③ AI 학습용 데이터 라이프사이클 관리체계 구축 및 제공
체계 정비	■ 분산된 AI 학습용 데이터 등록체계 마련	① AI 학습용 데이터 탐색 및 발굴을 위한 체계 마련 ② AI 학습용 데이터 관리를 위한 협의체 운영
	■ AI 학습용 데이터 보상·상거래 체계 정비	① AI 학습용 데이터 보상 체계 마련 ② AI 학습용 데이터 상거래 체계 마련
	■ AI 학습용 데이터 거버넌스 체계 구축	① AI 학습용 데이터 품질관리체계 확보 ② AI 학습용 데이터 개발 및 활용에 필요한 지원체계 마련
파일럿 과제	■ 국가 AI모델 전용 플랫폼 확보	① 국가 AI모델 학습데이터 관리
법·제도	■ AI 학습용 데이터 법·제도 연구 및 개선	① AI 학습용 데이터를 위한 법·제도 개선 연구

자료: 지능정보사회원, “AI 학습용 데이터 통합제공체계 구축 방안”, 2025년 9월

29) 2026년 12월 중 시범 운영 개시 예정

다. 기관 간 사전협의로 유사한 학습용 데이터 구축 문제를 해결한 사례

한편, 과기정통부와 문체부(업무위탁기관: 국립국어원)는 2020. 10. 16. ‘말뭉치 학습용 데이터 구축’에 관해 다음과 같이 사전 업무 협의를 실시하여 개별 공공기관별로 학습용 데이터를 각각 구축할 경우 발생할 수 있는 유사한 학습용 데이터의 구축 문제를 해결하였다.

<유사 데이터 구축 방지 사례>

- (한국어 말뭉치) ① 한국어 원시·분석 말뭉치 구축은 국어 정책 주관 부서인 문체부(국립국어원)에서 추진하고, ② 특정 영역(domain) 및 기술적 환경을 고려한 한국어 자료는 과기정통부에서 추진
- (한국어-외국어 말뭉치) ① 한국어 학습수요가 많은 신남방·신북방 언어는 문체부에서 추진, ② 영어, 중국어, 일본어 등 주요 언어는 과기정통부에서 추진
- (한국수어 말뭉치) 한국수어 말뭉치 구축은 한국수어 정책 주관 부서인 문체부(국립국어원)에서 추진

하지만, 위와 같은 사례와 달리 개별 공공기관이 AI Hub 등에 이미 구축·공개된 학습용 데이터를 대체 활용 가능한지, 신규 학습용 데이터를 별도로 구축할 필요가 있는지 등에 대한 사전 검토 없이 개별 공공기관 자체의 필요에 따라 인공지능 학습용 데이터를 별도로 구축할 경우, 유사한 학습용 데이터 구축에 예산이 추가로 투입되고, 데이터 구축 이후 유지관리 비용까지 중복적으로 소요되는 등 예산 집행의 비효율이 발생하는 한편, 유사한 학습용 데이터로 인해 수요자가 인공지능 모델 학습에 필요한 학습용 데이터를 선택하는 데 혼선이 발생³⁰⁾할 우려가 있다.

이에 이번 감사원 감사기간(2025. 11. 26.~12. 19.) 중 2025년 11월 기준 과기정통부가 구축하여 AI Hub를 통해 공개 중인 인공지능 학습용 데이터(908종)와 개별 공공기관이 구축하여 공개 중인 인공지능 학습용 데이터(313종)의 유사

30) 원-원도우 포털에 2020. 1. 1.부터 2025. 12. 19. 기간에 등록된 ‘자율주행 학습용 데이터’를 검색할 경우 데이터 25개가 검색되어 인공지능 학습모델 개발에 필요한 적정한 데이터 선택에 추가적인 시간이 소요됨

여부를 비교·분석하여 인공지능 학습용 데이터 구축사업의 제도적 개선방안을 마련하고자 하였다.

3. 감사결과 확인된 문제점

가. 분석대상 및 범위

과기정통부에서 2025년 11월 현재 AI Hub에 공개 중인 학습용 데이터 908종 및 개별 공공기관이 별도로 구축하여 개별포털·공공데이터포털 등을 통해 공개하고 있는 학습용 데이터 313종³¹⁾을 대상으로 [표 14]와 같이 ① 해당 학습용 데이터의 구축 목적이 동일·유사한지, ② 학습 대상 객체 또는 판별 대상이 공통되는지, ③ 최종 활용 기능 및 서비스 목적이 유사한지를 순차적으로 점검³²⁾하여 유사 구축 사례를 분석³³⁾하였다.

[표 14] 인공지능 학습용 데이터 유사성 분석 기준

유사성 판단 단계	주요 검토 내용
① 구축 목적	■ 해당 데이터가 인공지능 모델 학습 과정에서 수행하도록 설계된 과업이 무엇인지
② 학습 대상	■ 인공지능이 학습·판별하는 대상이 무엇인지
③ 활용 기능 및 서비스 목적	■ 구축된 데이터가 실제로 어떤 기능·서비스에 활용되는지

나. 분석결과

1) 이미 구축된 학습용 데이터를 확인하지 않고 새로 구축한 사례³⁴⁾

과기정통부에서 2020년부터 2022년 사이에 생활폐기물(구축연도 2020년),

31) 감사기간(2025. 11. 26.~12. 19.) 중 개별 공공기관에서 자체적으로 응답한 자료로 일부 학습용 데이터의 누락이 있을 수 있음

32) 과기정통부(지능정보사회원)는 인공지능 학습용 데이터의 유사 여부는 1단계 메타데이터(데이터명, 구축 목적 등), 2단계 데이터 속성·내용(학습 대상 객체 범위, 수집 환경 등), 3단계 데이터 정밀도 및 가공 수준을 기준으로 판단할 수 있는데, 데이터 수집 환경, 대상 범위 등이 다르더라도 데이터 구축 목적, 학습 대상, 활용 기능 및 서비스 목적 등이 유사한 경우 기존에 구축된 데이터를 일부 활용하는 것은 가능하다는 의견 제시

33) AI Hub가 인공지능 학습용 데이터를 구축 목적·학습 대상·활용 서비스 중심으로 제공하고 있으며, 영국 정부가 “Code of Practice for Statistics”에서 새로운 데이터를 수집하기 전 기존 데이터의 적합성과 이용 가능성을 확인하도록 하고 있는 점 등을 종합하여 설정

34) 과기정통부는 ‘유사한 AI 학습용 데이터 구축 사례’는 대상 객체 범위, 수집 환경 등은 다르지만, 데이터 구축 목적, 학습 대상 등이 유사하므로 사전에 다른 기관에서 유사한 데이터가 구축된 사실을 알 수 있었다면, 각 기관은 신규 데이터 구축 시 해당 데이터의 활용 가능성을 검토하고 인공지능 학습에 보완적으로 활용함으로써, 목표 인공지능 모델의 성능 제고, 신뢰성 강화, 예산 투입 대비 성과 제고 등이 가능했을 것으로 보인다는 의견을 제시

야생동물(구축연도 2021년), 콘크리트 균열(구축연도 2020년), 계란(구축연도 2022년) 등 4종의 학습용 데이터를 이미 구축하여 AI Hub에 공개 중인데도, 개별 공공기관에서 위 학습용 데이터의 대체 활용 가능성 등을 확인하지 않은 채 [표 15]와 같이 ① 구축 목적, ② 학습 대상, ③ 활용 기능 및 서비스 목적 등이 유사한 학습용 데이터를 별도로 구축하여 개별포털(예: 서울열린데이터광장) 등에 공개하고 있었다.

[표 15] 인공지능 학습용 데이터를 새로 구축한 사례

(단위: 백만 원)

구분	기관	구축 연도	사업비	학습용 데이터명	유사성 판단		
					① 구축 목적	② 학습 대상	③ 활용기능 및 서비스 목적
생활 폐기물	과기정통부 (지능정보사회원)	2020	1,600	생활폐기물 이미지	생활폐기물 탐지 및 분류	생활 폐기물 128종류 이미지	생활 폐기물 인식, 분류 자동화 모델로 폐기물 배출·수거·관리
	서울특별시	2020	21	대형폐기물 학습데이터	대형폐기물 탐지 및 식별	대형폐기물 79종류 이미지	대형폐기물 인식, 분류 자동화 모델로 폐기물 배출·수거·관리
	대전광역시 서구	2025	130	생활폐기물 이미지 라벨링 AI 학습용 데이터(45종)	폐기물 탐지 및 분류	생활폐기물 45종류 이미지	폐기물 인식, 분류 자동화 모델로 폐기물 배출·수거·관리
야생 동물	과기정통부 (지능정보사회원)	2021	2,027	야생동물 활동 영상 데이터	야생동물의 탐지·인식 및 활동 식별	야생동물 11종류 객체 이미지와 활동 정보	로드킬 방지, 야생동물 모니터링 및 보전·관리
	한국도로공사	2022	284	야생동물 종 분류 학습데이터셋		야생동물 12종류 객체 이미지	로드킬 방지 및 도로 중심 안전 확보를 위한 모니터링
콘크리트 균열	과기정통부 (지능정보사회원)	2020	2,191	건물 균열 탐지 이미지	콘크리트 및 금속 강재 구조물 표면의 결함 탐지·진단	건물·교량·담·벽면 등 구조물 표면의 손상부 드론 중심 촬영 이미지	시설물 안전점검, 손상 진단, 유지보수 의사결정 지원
	서울시재단	2023	143	콘크리트 구조물 표면 손상 결함 데이터	콘크리트 구조물 표면의 결함 탐지·진단	교량, 건물, 터널 등 콘크리트 표면의 손상부 카메라(DSLR) 촬영 이미지	
계란	과기정통부 (지능정보사회원)	2022	1,562	계란 데이터	계란 외관·투광 이미지상 이상란 판정	껍데기 오염, 표면 이상이 있는 계란 투광 이미지	이상란 판정, 신선도 분석, 품질관리 자동화 서비스 개발
	축산물 품질평가원	2024	33	계란 등급 판정 이미지 자료	계란 외관상 이상란 판정	계란 판정 시 오염과 탈색 계란 외관 이미지	크랙 등의 외관상 이상란 판정 서비스 고도화

자료: AI Hub, 공공데이터포털 공개자료 및 지능정보사회원 등 제출자료 재구성

이에 개별 공공기관이 별도로 구축하여 공개 중인 위 4종의 사례 중 생활 폐기물 학습용 데이터와 야생동물 학습용 데이터 등 2종의 데이터에 대하여 ① 구축 목적, ② 학습 대상(이미지), ③ 활용 기능 및 서비스 목적 등을 중심으로 유사성을 구체적으로 살펴보면 다음과 같다.³⁵⁾

가) 생활폐기물 학습용 데이터 관련

생활폐기물 학습용 데이터의 구축 목적은 생활폐기물의 탐지 및 분류를 위한 인공지능 기반 서비스 모형 개발을 지원하고, 분리배출·수거·선별 등 자원순환 과정의 효율성을 제고하기 위한 것이다.

이와 관련, 과기정통부에서 2020년에 ① 생활폐기물의 이미지 탐지·분류 및 객체 위치 라벨링을 주된 구축 목적으로 하고, ② 생활폐기물 128종류를 학습 대상(이미지 150,000장)으로 하며, ③ 폐기물 자동 인식과 배출·수거·관리 업무 지원 기능 및 서비스를 제공하는 생활폐기물 학습용 데이터를 구축(사업비 16억 원)하여 AI Hub를 통해 공개하고 있는데도, 서울특별시, 대전광역시 서구는 각각 2020년과 2025년에 동일한 ① 구축 목적, ② 학습 대상, ③ 활용 기능 및 서비스 목적을 제공하는 생활폐기물 학습용 데이터를 별도로 구축하여 공개하고 있었다.

구체적으로 학습용 데이터의 유사성을 학습 대상(생활폐기물 이미지)을 중심으로 살펴보면, 과기정통부에서 구축하여 AI Hub를 통해 공개 중인 생활폐기물 학습용 데이터 학습 대상(128종류)과 비교할 때, [표 16]과 같이 대전광역시 서구의 생활폐기물 학습용 데이터 학습 대상(45종류)은 26종류가 공통되고, 대전광역시 서구 생활폐기물 학습용 데이터 학습 대상 45종류의 전체 이미지 9,000장 중 공통 학습 대상(26종류) 이미지 5,200장(57.8%)이 AI Hub를 통해 공개 중인 생활폐기물

35) 감사원이 구축 목적, 학습 대상 및 활용 기능 등을 기준으로 유사성이 의심되는 학습용 데이터를 추출한 후 지능정보사회원에 의뢰하여 개별 이미지의 유사성을 점검

학습용 데이터 학습 대상 이미지와 유사한 것으로 확인되었다.

[표 16] 생활폐기물 학습용 데이터의 학습 대상 및 이미지 비교

(단위: 백만 원, 장, %)

구분	과기정통부(지능정보사회원)	대전광역시 서구	서울특별시
사업비	1,600	130	21
데이터 종류	■ 생활폐기물 이미지(대분류 15종류) 128종류	■ 생활폐기물 이미지 45종류	■ 생활폐기물 이미지 79종류
이미지 수	150,000	9,000	2,303
공통 학습 대상		■ 냉장고, 의자 등 26종류	■ 냉장고, 의자 등 38종류
공통 학습 대상 이미지 수(비율 ^{주)})		5,200(57.8)	1,454(63.1)
이미지 예시			

주: 이미지 유사 비율은 서울특별시, 대전광역시 서구 이미지 수를 기준으로 계산

자료: AI Hub, 서울열린데이터광장, 공공데이터포털 공개자료 및 지능정보사회원 등 제출자료 재구성

그리고 서울특별시의 경우를 살펴보면, 생활폐기물 학습용 데이터 학습 대상(79종류)은 AI Hub를 통해 공개 중인 생활폐기물 학습용 데이터의 학습 대상(128종류)과 38종류가 공통되고, 서울특별시 생활폐기물 학습용 데이터 학습 대상 79종류의 전체 이미지 2,303장 중 공통 학습 대상(38종류) 이미지 1,454장 (63.1%)이 AI Hub를 통해 공개 중인 생활폐기물 학습용 데이터 학습 대상 이미지와 유사한 것으로 확인되었다.³⁶⁾

나) 야생동물 학습용 데이터 관련

야생동물 학습용 데이터의 구축 목적은 인공지능을 활용해 야생동물을 자동으로 식별·모니터링하여 로드킬 예방, 밀렵 방지 등 야생동물의 보전 및 보호 전략을 효과적으로 수립하기 위한 것이다.

이와 관련하여 과기정통부에서 2021년에 ① 야생동물의 탐지·인식 및 활동

36) 서울특별시 생활폐기물 학습용 데이터의 경우 과기정통부와 구축연도(2020년)가 동일하므로 “3-나-2)”에서 실시하여야 하나, 이해의 편의를 위해서 대전광역시 서구가 2025년에 구축한 생활폐기물 학습용 데이터와 함께 실시하였음

식별을 주된 구축 목적으로 하고, ② 야생동물 11종류를 학습 대상(이미지 334,851장)으로 하며, ③ 로드킬 방지, 야생동물 모니터링 및 보전·관리 업무 지원 기능 및 서비스를 제공하는 야생동물 학습용 데이터를 구축(사업비 20억여 원)하여 AI Hub를 통해 공개하고 있는데도, 한국도로공사는 2022년에 동일한 ① 구축 목적, ② 학습 대상, ③ 활용 기능 및 서비스 목적을 제공하는 야생동물 학습용 데이터를 별도로 구축하여 공개하고 있었다.

구체적으로 학습용 데이터의 유사성을 학습 대상(야생동물 이미지)을 중심으로 살펴보면, 과기정통부에서 구축하여 AI Hub를 통해 공개 중인 야생동물 학습용 데이터 학습 대상(11종류)과 비교할 때, [표 17]과 같이 한국도로공사의 야생동물 학습용 데이터 학습 대상(12종류)은 AI Hub를 통해 공개 중인 야생동물 학습용 데이터와 5종류가 공통되고, 한국도로공사 야생동물 학습용 데이터 학습 대상 12종류의 전체 이미지 60,000장 중 공통 학습 대상(5종류) 이미지 25,000장(41.7%)이 AI Hub를 통해 공개 중인 야생동물 학습용 데이터 학습 대상 이미지와 유사하다.

[표 17] 야생동물 학습용 데이터 학습 대상 및 이미지 비교

(단위: 백만 원, 장, %)

구분	과기정통부(지능정보사회원)	한국도로공사
사업비	2,027	284
데이터 종류	■ 야생동물 이미지 11종류 및 활동 영상데이터	■ 야생동물 이미지 12종류
이미지 수	334,851	60,000
공통 학습 대상	■ 야생동물 이미지 5종류(고라니, 멧돼지, 너구리, 족제비, 노루)	
공통 학습 대상 이미지 수(비율 ^{주)})	25,000(41.7)	
이미지 예시		

주: 이미지 유사 비율은 한국도로공사 이미지 수를 기준으로 계산

자료: AI Hub, 고속도로 공공데이터 포털 공개자료 및 지능정보사회원 등 제출자료 재구성

2) 기관 간 구축 계획을 사전 공유·조정하지 않아 같은 연도에 유사한 학습용 데이터를 구축한 사례

과기정통부에서 2021년부터 2023년 사이에 구축하여 AI Hub에 공개 중인 알약(구축연도 2021년), 구강(구축연도 2023년), 자율주행(구축연도 2022년) 등 3종의 학습용 데이터의 경우에 기관 간 학습용 데이터 구축 계획을 사전에 공유·조정하지 않아 [표 18]과 같이 과기정통부와 개별 공공기관의 구축 사업연도가 같은 것을 확인할 수 있었다.

[표 18] 인공지능 학습용 데이터를 같은 연도에 구축한 사례

(단위: 백만 원)

구분	기관	구축 연도	사업비	학습용 데이터명	유사성 판단		
					① 구축 목적	② 학습 대상	③ 활용 기능 및 서비스 목적
알약	과기정통부 (지능정보사회원)	2021	2,172	경구약제 이미지 데이터	알약경구약제의 외형 이미지를 인식하여 의약품을 식별	경구약제품목 4,999종류	의약품 조회, 복약 지원, 안전한 약물 사용 지원
	식약처	2021	432	인공지능 개발을 위한 알약 이미지 데이터		경구약제품목 5,098종류	
구강	과기정통부 (지능정보사회원)	2023	1,753	구강 이미지 합성 데이터	구강 이미지를 분석하여 치아 상태 및 질환 여부를 식별·판단	정면, 상, 하, 좌, 우 구강 이미지	치과 진단 지원, 구강질환 판별, 치아 상태 분석
	개보위	2023	308	구강 이미지 합성 데이터		상, 하 구강 이미지	합성데이터 생성 예시로 참고용
자율주행	과기정통부 (지능정보사회원)	2022	19,382	‘상용 자율주행차 주간 자동차 전용도로 데이터’ 등 ^{주)}	다양한 상황과 객체에 대한 인지 기능 향상	10종의 이동수단, 22종의 도로, 13종의 객체 이미지	차량·보행자·도로를 판별하고 분석하는 자율주행 기술 개발, ADAS·인지 시스템 고도화
	한국저작권위원회	2022	100	자율주행 인공지능 원천데이터	차량 및 보행자 객체 인지 기능 향상	주로 수도권 일반 도로에서 수집한 차량 및 보행자 라이더 이미지 데이터	

주: ‘상용 자율주행차 주행 데이터’ 등 2개 과제에서 총 10개의 데이터를 구축

자료: AI Hub, 공공데이터포털 공개자료 및 지능정보사회원 등 제출자료 재구성

이에 개별 공공기관이 구축 계획을 사전에 공유·조정하지 않고 각자 구축하여 공개한 위 3종의 사례 중 알약 학습용 데이터와 구강 학습용 데이터에 대하여 ① 구축 목적, ② 학습 대상, ③ 활용 기능 및 서비스 목적 등을 중심으로 유사성을 구체적으로 살펴보면 다음과 같다.

가) 알약 학습용 데이터 관련

알약 학습용 데이터의 구축 목적은 알약의 형태, 색상, 패턴 등 시각 정보를 체계적으로 구축·정리하여 인공지능 기반 알약 인식 모델 및 약물 관리 서비스 개발을 위한 고품질의 학습용 데이터를 제공하고, 약물 오남용 예방 및 의약품 안전관리 수준 제고에 기여하고자 하는 것이다.

이와 관련, 과기정통부와 식약처가 2021년 같은 연도에 구축한 알약 학습용 데이터의 경우, ① 구축 목적이 알약·경구약제의 외형 이미지를 인식하여 의약품을 식별하는 것으로 일치하고, ② 학습 대상도 경구 투여 의약품, 알약, 정제·캡슐 등 약제 이미지로 동일하며, ③ 활용 기능 및 서비스 목적 또한 의약품 조회, 복약 지원, 안전한 약물 사용 지원으로 같다.

구체적으로 학습용 데이터의 유사성을 학습 대상(품목명)을 중심으로 살펴보면, 과기정통부에서 구축하여 AI Hub를 통해 공개 중인 알약 학습용 데이터(4,999종류)와 비교할 때, [표 19]와 같이 식약처의 알약 학습용 데이터(5,098종류)는 AI Hub를 통해 공개 중인 알약 학습용 데이터와 1,411종류(27.7%)의 이미지가 유사한 것으로 확인되었다.

[표 19] 알약 학습용 데이터 학습 대상 및 이미지 비교

(단위: 백만 원, 장, %)

구분	과기정통부(지능정보사회원)	식약처
사업비	2,172	432
데이터 종류	■ 경구약제 품목 4,999종류	■ 경구약제 품목 5,098종류
총 이미지 수	2,778,975	407,840
공통 학습 대상	■ 알약 품목 1,411종류(엘씨500연질캡슐, 가스티렌정, 가스파민정, 낙센에프정, 디레인캡슐 등)	
공통 학습 대상 수(비율 ^{주)})	1,411(27.7)	
공통 학습 대상 이미지 예시	엘씨500연질캡슐	
		

주: 알약 데이터의 경우 이미지 용량(2TB)이 커 품목명이 일치한 알약으로 분석

자료: AI Hub 공개자료, 지능정보사회원 및 식약처 제출자료 재구성

나) 구강 학습용 데이터 관련

구강 학습용 데이터 구축 목적은 구강 내 사진, 스캔, 진단·치료 기록 등 실제 임상데이터를 수집·정리해 딥러닝³⁷⁾·컴퓨터 비전모델³⁸⁾이 질환(예: 충치, 교합이상 등)을 학습하는 등 인공지능 기반 구강 진료·질환진단 및 치료 지원 기술을 개발·고도화하기 위한 ‘양질의 구강 관련 데이터 자원’을 체계적으로 마련하는 데 있다.

이와 관련, 과기정통부와 개보위가 2023년 같은 연도에 구축한 구강 학습용 데이터의 경우, ① 구축 목적이 구강 이미지를 분석하여 치아 상태 및 질환 여부를 식별·판단하는 것으로 일치하고, ② 학습 대상도 구강 이미지로 동일하며, ③ 활용 기능 및 서비스 목적 또한 치과 진단 지원, 구강질환 판별, 치아 상태 분석으로 같다.

구체적으로 학습용 데이터의 유사성을 학습 대상(구강 이미지)을 중심으로 살펴보면, 과기정통부에서 구축하여 AI Hub를 통해 공개 중인 구강 학습용 데이터 학습 대상(5종류)과 비교할 때, [표 20]과 같이 개보위의 구강 학습용 데이터 학습 대상(2종류)은 AI Hub를 통해 공개 중인 구강 학습용 데이터와 2종류 모두 공통되고, 개보위의 구강 학습용 데이터 학습 대상 2종류의 전체 이미지 1,000장은 AI Hub를 통해 공개 중인 구강 학습용 데이터 학습 대상 이미지와 모두(100%) 유사³⁹⁾한 것으로 확인되었다.

37) 딥러닝은 인공지능의 한 분야로 인공신경망을 기반으로 한 기계학습 기법으로 인간의 뇌 뉴런 구조를 모방한 다층 신경망을 활용해 데이터에서 복잡한 패턴을 학습하고 예측·분류·생성을 수행

38) 이미지·영상에서 의미 있는 정보를 추출하거나 판단하는 모델

39) 과기정통부(지능정보사회원)의 경우 상·하악뿐 아니라 치아 앞·좌·우면 사진도 포함하여 구축 대상 범위가 더 넓음

[표 20] 구강 학습용 데이터 학습 대상 및 이미지 비교

(단위: 백만 원, 장, %)

구분	과기정통부(지능정보사회원)	개보위
사업비	1,753	308
데이터 종류	■ 치아 정면, 상, 하, 좌, 우 5종류	■ 치아 상, 하 2종류
이미지 수	145,140	1,000
공통 학습 대상	■ 치아 상, 하 2종류	
공통 학습 대상 이미지 수(비율 ^{주)})	1,000(100)	
이미지 예시		

주: 이미지 유사 비율은 개보위 이미지 수를 기준으로 계산

자료: AI Hub 공개자료, 지능정보사회원 및 개보위 제출자료 재구성

4. 소결

“3-나-1)”과 같이 개별 공공기관이 신규 학습용 데이터를 구축할 때 이미 구축한 학습용 데이터를 확인하여 대체 활용 가능성 등을 확인하지 않고 유사한 학습용 데이터(학습 대상 이미지)를 다시 구축하거나, “3-나-2)”와 같이 개별기관 간 학습용 데이터 구축 계획을 사전에 공유·조정하지 않아 유사한 학습용 데이터를 동시에 구축할 경우 예산 집행이 효율적으로 이루어지지 않거나 수요자가 인공지능 모델 학습에 필요한 학습용 데이터를 선택하는 데 혼선이 발생할 우려가 있다.

따라서 개별 공공기관에서 별도로 학습용 데이터를 구축하기에 앞서 이미 과기정통부 및 개별 공공기관 등에서 구축한 학습용 데이터를 대체 활용하여 필요한 부분만 추가로 구축하고, 개별 공공기관 간 인공지능 학습용 데이터 구축 계획을 사전 공유·조정하는 등 사전 검토체계 마련이 필요한 것으로 보인다.

5. 관계기관 의견

과기정통부는 감사원의 지적에 전반적으로 이견이 없다는 의견을 제시하며, 통합제공체계 구축 시 가능한 범위에서 공공기관의 데이터 구축 현황 등을 포함할

예정으로 국가기관 등이 인공지능 학습용 데이터가 산출되는 사업을 추진하는 경우 기존 구축된 데이터와의 유사 여부 등을 사전에 자체 점검하는 절차를 마련하여 기존 데이터 재활용 가능 여부 검토, 데이터 공유·확산 등 예산 투입 대비 성과를 제고할 필요가 있다는 의견을 제시하였다.

이를 위해 기획예산처와 협의하여 공공기관 등으로 하여금 기존 구축된 데이터와의 유사 여부 등을 자체 점검하고 그 결과를 제출하도록 하여 기획 단계에서 중복투자를 방지하고 데이터 연계·공유를 강화하는 내용의 2027년 예산안 편성 및 기금운용계획안 작성·세부지침 개정을 추진⁴⁰⁾하고 있으며, 각 기관이 참고할 인공지능 학습용 데이터 구축·활용을 위한 가이드를 마련하고 지방자치단체 배포는 행안부와 협의 등을 추진 중이라는 의견을 제시하였다.

한편 행안부도 앞으로 정부가 인공지능 학습용 데이터로 직접 가공하여 제공하는 방식에 대한 시장 수요가 지속 증가할 것으로 예상됨에 따라 유사한 인공지능 학습용 데이터 구축은 최소화하고, 공공기관이 양질의 인공지능 학습용 데이터를 효율적으로 구축할 수 있도록 인공지능기본법상의 인공지능 학습용 데이터 총괄 부처인 과기정통부와 협력하여 제도적 보완을 모색하겠다는 의견을 제시하였다.

조치할 사항 과학기술정보통신부장관은 행정안전부장관과 협의하여 개별 공공기관에서 인공지능 학습용 데이터 구축 시 이미 구축된 데이터의 대체 활용 가능성을 사전에 검토하고, 기관별 데이터 구축 계획을 사전에 공유·조정하는 등의 사전 검토체계를 도입하는 방안을 마련하시기 바랍니다.(통보)

40) 2026년 3월 「2027년 예산안 편성지침」을 개정하였고, 개정 내용은 ① 인공지능 사업 추진 시 데이터 확보 계획을 포함하고, 사업 추진 과정에서 생산된 데이터는 통합 관리·공동 활용을 우선 검토, ② AX[인공지능(AI) 전환: AI Transformation] 사업은 관계 부처 협의체를 통해 유사 구축을 최소화하고, 부처 간 노하우 공유와 컨설팅을 제도화하여 투자 효율성을 강화하도록 하는 것임

제3절 학습용 데이터 품질관리 분야

2 학습용 데이터 품질관리 기준 마련 필요

1. 업무 개요

과기정통부는 인공지능기본법 제15조 및 같은 법 시행령 제12조 제1항에 따라 관계 중앙행정기관의 장과 협의하여 인공지능 학습용 데이터의 생산·수집·관리·유통·활용 촉진 및 품질수준 확보 등에 관한 사업을 추진하고 있다.

고품질의 인공지능 학습용 데이터를 확보하기 위해서는 원시·원천·가공데이터 등 공정별 데이터 자체의 품질은 물론, 이를 사용자 요구에 맞춰 지속적으로 유지·향상시킬 수 있는 품질관리 체계가 필요하다.

이에, 과기정통부는 지능정보사회원⁴¹⁾과 함께 [표 21]과 같이 2021년 2월 「인공지능 학습용 데이터 품질관리 가이드라인 v1.0」을 공개하며 공공데이터 품질관리⁴²⁾와는 구별되는 인공지능 학습용 데이터 전용 품질관리 기준을 마련하였다.

이후 2025년 2월 인공지능 학습용 데이터에서 초거대·생성형 인공지능 데이터⁴³⁾ 품질관리까지 포괄하는 「AI 데이터 품질관리 가이드라인 v3.5」를 공개하는 등 인공지능 학습용 데이터 품질관리 기준을 고도화하고 있다.⁴⁴⁾

41) 과기정통부는 지능정보화법 제12조에 따라 지능정보화 전문기관으로 지능정보사회원을 설립하고, 국가 지능정보화 정책 및 관련 사업의 추진을 지원하는 역할을 수행하도록 함

42) 행안부는 「공공데이터 품질관리 매뉴얼 v2.0」을 마련하였고 이후 공공데이터 품질관리 수준평가 및 「공공데이터 예방적 품질관리 진단 가이드」, 공공데이터 품질인증 제도를 도입하여 공공데이터 품질·표준관리 통합시스템을 구축

43) 초거대·생성형 인공지능 데이터란 특정 과업의 학습을 목적으로 하는 인공지능 학습용 데이터와 달리, 모델이 언어·이미지·지식·추론 방식·대화 방식 등을 폭넓게 학습하도록 만든 범용 데이터를 말함

44) 감사원 감사 이후 2026. 2. 27. 과기정통부와 지능정보사회원은 「AI 데이터 품질관리 가이드라인 v4.0」을 공개

[표 21] 인공지능 학습용 데이터 품질관리 가이드라인

공개 시점	공식 명칭	내용
2021년 2월	「인공지능 학습용 데이터 품질관리 가이드라인 v1.0」	■ AI 학습용 데이터 사업 적용 기반 마련을 위해 최초로 품질 확보 목적의 가이드라인 공개
2022년 2월	「인공지능 학습용 데이터 품질관리 가이드라인 v2.0」	■ v1.0에 2021년 AI Hub 학습용 데이터 구축 사업 (당시 190종) 및 품질관리 고도화 작업 반영
2023년 2월	「인공지능 학습용 데이터 품질관리 가이드라인 및 구축 안내서 v3.0」	■ 다년간 축적된 품질관리 활동·산출물을 프로세스화 하여 '품질관리 프레임워크'로 재구성
2024년 1월	「인공지능 학습용 데이터 품질관리 가이드라인 v3.1」	■ 2023년 구축사업 내용 현행화
2025년 2월	「AI 데이터 품질관리 가이드라인 v3.5」	■ 2024년 '초거대AI 확산 생태계 조성사업' 수행 내용 기반으로 제작

자료: 지능정보사회원, 「AI 데이터 품질관리 가이드라인 v3.5」, 2025년 2월

2. 감사접근 방법

과기정통부는 [표 22]와 같이 AI Hub를 통해 2025년 11월 기준 인공지능 학습용 데이터 908종을 공개하고 있고, 개별 공공기관도 개별포털 등을 통해 인공지능 학습용 데이터 313종을 공개하고 있으며, 학습용 데이터와 별개로 행안부는 2026년 5월 현재 공공데이터포털을 통해 107,511건의 공공데이터를 공개하고 있다.

[표 22] 인공지능 학습용 데이터 및 공공데이터 공개 현황

구분	인공지능 학습용 데이터		공공데이터
주무 부처	과기정통부	행안부	행안부
구축 기관	지능정보사회원	개별 공공기관	개별 공공기관
공개 시스템	AI Hub	개별 공공기관 포털 등	공공데이터포털
데이터 수 ¹⁾²⁾	908종	313종	107,511건
품질관리 기준	「AI 데이터 품질관리 가이드라인 v3.5」	공통 품질관리 기준 없음	「공공데이터 품질관리 매뉴얼 v2.0」 등
근거 법령 등	인공지능기본법 제15조	인공지능기본법 제15조, 개별 사업 지침	공공데이터법 제21조 등

주: 1. 데이터 수는 감사기간 기준으로 집계되어 실제 제공 데이터 수와 상이할 수 있음

2. 인공지능 학습용 데이터의 '종'은 원천데이터, 가공데이터, 메타데이터 등을 하나의 데이터세트로 묶은 단위이며, 공공데이터의 '건'은 공공데이터포털 등에 공개된 각각의 데이터 파일·API·목록 단위로 집계 기준에 차이가 있음

자료: 지능정보사회원 등 제출자료 재구성

과기정통부의 「AI 데이터 품질관리 가이드라인 v3.5」에 따르면 인공지능 학습용 데이터 품질관리는 [그림 4]와 같이 품질 자가점검과 제3자 품질검증으로 나누어 2단계로 수행하도록 하고 있는데, ① 품질 자가점검은 인공지능 학습용 데이터를 구축하는 사업수행기관이 데이터 오류나 규격 위반이 있는지 직접 확인하도록 하고 있으며, ② 제3자 품질검증은 데이터 납품 전 최종적으로 정해진 데이터 품질지표 기준을 충족하는지 품질검증 전문기관을 통해 검증받도록 하고 있다.

[그림 4] 인공지능 학습용 데이터 품질관리



자료: 지능정보사회원, 「AI 데이터 품질관리 가이드라인 v3.5」, 2025년 2월

이에, 과기정통부는 AI Hub를 통해 공개하는 인공지능 학습용 데이터 (908종)의 경우 「AI 데이터 품질관리 가이드라인 v3.5」에 따라 ① 사업수행기관이 사업수행기간 중 지속적으로 품질 자가점검을 하도록 하고 있으며, ② 인공지능 학습용 데이터 납품 전에 품질검증 전문기관인 기술협회의 품질검증을 받도록 하고, ③ 지능정보사회원에서 품질점검 활동 결과물의 적정성 및 제3자 품질검증 결과를 확인하는 등 인공지능 모델 학습에 적합한 데이터 품질수준을 확보하기 위해 노력하고 있다.

하지만, 개별 공공기관이 구축하여 개별포털(예: 서울열린데이터광장) 등을

통해 공개하는 인공지능 학습용 데이터(313종)의 경우는 개별 공공기관이 준수하여야 할 공통된 인공지능 학습용 데이터 품질관리 기준이 없어, 개별 공공기관별로 품질 자가점검 기준이 상이하거나 제3자 품질검증을 거치지 않는 등으로 인공지능 모델 학습에 사용하기 어려운 낮은 품질의 데이터가 제공될 우려가 있다.

한편, “2023 인공지능산업 실태조사”에서 인공지능 기업들은 공공부문에서 ‘양질의 학습용 데이터 확보의 어려움’과 ‘품질 저하’를 애로사항으로 제시하고 있다.

이에, 이번 감사원 감사기간(2025. 11. 26.~12. 19.) 중 개별 공공기관에서 인공지능 학습용 데이터를 구축할 때 적용하는 품질관리 기준 및 개별포털(예: 서울열린데이터광장) 등을 통해 공개하고 있는 인공지능 학습용 데이터의 품질관리 수준 등을 비교·분석하여 문제점을 도출한 후 제도적 개선안을 마련하고자 하였다.

3. 감사결과 확인된 문제점

가. 분석대상 및 범위

감사기간 중 26개 개별 공공기관이 313종의 인공지능 학습용 데이터를 구축하여 공개하고 있다는 사실을 파악⁴⁵⁾하고, 이 중 인공지능 학습용 데이터 구축 실적이 높은 상위 20개 기관을 대상으로 ① 인공지능 학습용 데이터 구축 시 적용하는 품질관리 기준이 있는지, ② 품질 자가점검 및 제3자 품질검증은 실시하는지, ③ 인공지능 학습용 데이터의 품질수준은 어떠한지에 관해 분석하였다. 한편, 일부 인공지능 학습용 데이터(6종)의 품질수준은 품질검증 전문기관인 기술협회에 품질검증 용역을 의뢰하고, 그 결과를 감사결과에 활용하였다.

45) 공공기관에서 자체적으로 응답한 자료로 일부 응답의 누락이 있을 수 있어 이번 감사에서 실시된 실태조사가 국내에서 개별 공공기관이 구축한 인공지능 학습용 데이터의 품질관리 현황을 빠짐없이 확인한 것으로 보기는 어려움

품질검증 영역의뢰 개요

- (검증기관) 기술협회⁴⁶⁾
- (시험기간) 2026. 4. 29.~5. 14.
- (구축기관) 경기도, 한국도로공사
- (용역대상) 인공지능 학습용 데이터 6종의 가공데이터 구문 정확성 등 품질수준 검증

나. 분석결과

[표 23]과 같이 학습용 데이터를 구축·공개하고 있는 상위 20개 기관 중 ① 4개 기관은 품질관리 기준이 없었고, ② 품질검증과 관련하여 2개 기관은 품질자가점검 및 제3자 품질검증을 모두 실시하지 않았으며, ③ 구문 정확성⁴⁷⁾ 품질검증을 실시한 2개 기관의 6종의 학습용 데이터는 모두 구문 정확성의 품질이 낮은 것으로 확인되었다.

[표 23] 점검기준별 분석결과 총괄

(단위: 개)

구분		보유 기관	품질검증 여부				구문 정확성 검증	
			자가점검		제3자 검증		불가	가능
품질 관리 기준	과기정통부 기준	5	5	－	5	－	－	5
	자체기준 등	11	13(2) ¹⁾	－	6	7	5	8(2) ²⁾
	미보유	4		2	－	2	2	－
계		20	18	2	11	9	7	13

주: 1. 기준 미보유 기관 중 경기도와 한국형사·법무정책연구원 2개 기관은 자체 지표·연구 보고서 등으로 품질자가점검을 실시했다고 주장하여 자가점검 실시로 분류하였음

2. 자체기준 등이거나 기준 미보유 기관 중 기술협회와 협의(데이터 크기, 검사 비용, 시간, 검사 가능한 형태의 구문규칙규격서 존재 여부 등 고려)하여 품질 의뢰 대상을 2개 기관(6종)으로 선정하였음

이에 대한 구체적인 내용은 다음과 같다.

1) 품질관리 기준 보유 여부

공공데이터법 제2조 제2호에 따르면 “공공데이터”란 데이터베이스, 전자화된

46) 방송통신발전법 제34조에 따라 정보통신의 표준 제정, 보급 및 정보통신 기술 지원 등 표준화에 관한 업무를 효율적으로 추진하기 위하여 과기정통부장관의 인가를 받아 설립된 기관으로서, 2023. 7. 6. 데이터산업법 제20조에 따라 과기정통부장관으로부터 데이터 품질인증기관으로 지정을 받음

47) 학습용 데이터 품질지표 9개 중 하나로 인공지능 모델 학습의 전제가 되며, 자세한 내용은 후술을 참조

파일 등 공공기관이 법령 등에서 정하는 목적을 위하여 생성 또는 취득하여 관리하고 있는 데이터이다.

공공기관은 법령 등에서 정하는 목적을 위하여 생성 또는 관리하고 있는 공공데이터에 그대로 접근하도록 하고 있는데, 행안부는 「공공데이터 품질관리 매뉴얼 ver2.0」을 마련하여 개별 공공기관으로 하여금 일정 수준의 공공데이터 품질을 확보하도록 하고 있다.

한편, 인공지능기본법 제2조 제12호에 따르면 학습용 데이터는 인공지능의 개발·활용 등에 사용되는 데이터로, 사람이 지식과 경험을 축적하며 성장하듯이 인공지능 역시 학습과 판단에 데이터(학습자료)가 필요하며, 양질의 학습용 데이터를 학습할수록 성능이 향상되는 반면, 잘못된 데이터는 인공지능 모델의 정확도를 크게 저해하는 요인으로 작용하므로 공공데이터와 달리 학습용 데이터 특성을 고려한 차별화 및 고도화된 품질관리 기준이 필요하다.

그런데 개보위(2종) 등 5개 기관은 [별표 1] “개별 공공기관별 품질관리 기준 및 품질검증 현황”과 같이 학습용 데이터 품질관리를 위한 과기정통부의 「인공지능 학습용 데이터 품질관리 가이드라인」을 학습용 데이터 구축 시 품질관리에 적용하고 있는 반면, 국립국어원(119종) 등 11개 기관은 사업수행기관 자체기준이나 공공데이터 품질관리를 위한 행안부의 「공공데이터 품질관리 매뉴얼 v2.0」 등을 학습용 데이터 구축 시 품질관리 기준으로 적용하고 있었고, 식약처(1종) 등 4개 기관은 학습용 데이터 구축 시 적용할 품질관리 기준을 가지고 있지 않았다.

2) 품질 자가점검 및 제3자 품질검증 실시 여부

분석대상 20개 공공기관 중 [별표 1] “개별 공공기관별 품질관리 기준 및 품질검증 현황”과 같이 ① 개보위(2종) 등 5개 기관은 과기정통부의 「인공지능

학습용 데이터 품질관리 가이드라인」을 적용하여 품질 자가점검 및 제3자 품질 검증 실시하고 있으나, ② 식약처(1종) 등 2개 기관은 인공지능 학습용 데이터 구축 시 적용할 품질관리 기준이 없다는 사유로 품질 자가점검 및 제3자 품질검증을 모두 실시하지 않은 채 인공지능 학습용 데이터를 구축하여 공개하고 있었고, ③ 국립국어원(119종) 등 나머지 13개 기관은 사업수행기관 자체기준이나 행안부의 「공공데이터 품질관리 매뉴얼 v2.0」 등을 적용하여 품질 자가점검을 하고 있으나 이 중 7개 기관은 제3자 품질검증⁴⁸⁾을 실시하지 않고 있었다.

3) 인공지능 학습용 데이터 품질수준 검증 결과

「AI 데이터 품질관리 가이드라인 v3.5」는 인공지능 학습용 데이터 품질관리 지표로 [표 24]와 같이 구축 공정 적정성(준비성·완전성·유용성), 데이터 적합성(기준 적합성·다양성), 가공데이터 정확성(구문 정확성·의미 정확성), 학습모델 적합성(알고리즘 적정성·유효성)을 제시하고 있다.

[표 24] 인공지능 학습용 데이터 품질지표 및 내용

구분	품질지표	설명
구축 공정 적정성	준비성	■ 인공지능 학습용 데이터 품질관리를 위해 기본적으로 관리해야 하는 정책, 규정(저작권, 초상권, 개인정보보호 및 정보보호 등에 대한 검토 결과를 포함), 조직, 절차 등을 마련하고, 최신의 내용으로 충실하게 관리되는지를 검사하는 지표
	완전성	■ 인공지능 학습용 데이터를 구축함에 있어 물리적인 구조를 갖추고, 정의한 데이터 형식 및 입력값 범위에 맞게 데이터가 저장되도록 설계·구축되었는지를 검사하는 지표
	유용성	■ 발주기관(수요자)의 요구사항이 충분히 반영되었는지, 임무 정의에 적합한 인공지능 학습용 데이터의 범위와 상세화 정도를 충족시키는지 검사하는 지표
데이터 적합성	기준 적합성	■ 원시데이터가 학습 용도로서 적합한지 기준을 선정하기 위해, 분류 다양성, 신뢰성, 충분성, 균일성, 사실성, 공정성, 형식성을 측정하는 지표
	다양성	■ 원천·가공데이터의 편향성을 방지하기 위해 데이터별 분포, 데이터별 수, 토큰 수 등을 측정하는 지표
가공데이터 정확성	구문 정확성	■ 어노테이션 데이터를 구성하는 속성값들과 원래 정의한 데이터 형식 및 입력값 범위와의 일치성을 측정하는 지표
	의미 정확성	■ 데이터의 참값(Ground Truth)을 확인하기 위해 정확도, 정밀도, 재현율 등을 측정하는 지표
학습모델 적합성	알고리즘 적정성	■ 알고리즘을 태스크(Task) 단위로 구분하여 사업수행기관이 제시하는 학습모델의 태스크가 적합한지 판단하는 지표
	유효성	■ 학습용 데이터로 학습시키는 데 적합한 인공지능 알고리즘의 유효성을 측정하는 지표

자료: 지능정보사회원, 「AI 데이터 품질관리 가이드라인 v3.5」, 2025년 2월

48) '발주기관 자체검증' 응답은 제3자의 품질검증을 거치지 않았으므로 '품질검증 미실시'로 분류

한편, 인공지능 학습용 데이터의 구축 과정에서 품질은 [그림 5]와 같은 과정을 거쳐 확보되는데, 원시데이터는 노이즈⁴⁹⁾가 있거나 형식에 차이가 있어 인공지능 모델 학습에 그대로 사용하기에는 적합하지 않다. 이에 원시데이터를 인공지능 모델 학습에 적합한 형식으로 조정하고 노이즈를 제거하는 한편, 개인 정보 비식별화 처리 등 정제 과정을 거치고, 인공지능 모델 학습 목적에 맞도록 라벨링·구조화 등을 거쳐 품질과 일관성을 확보하여 가공데이터를 획득하는데, 이를 통해 인공지능 모델 학습의 성능을 극대화할 수 있다.

[그림 5] 인공지능 학습용 데이터 구축 절차 및 품질



자료: 과기정통부 제출자료 재구성

인공지능 학습용 데이터의 품질지표 중 가공데이터의 구문 정확성 품질지표⁵⁰⁾는 어노테이션(Annotation)⁵¹⁾ 데이터의 구조와 속성값들이 정의된 규칙에 부합하는지 구조 정확성과 형식 정확성을 측정하는 품질지표로서, 구문규칙규격서⁵²⁾를 통해 인공지능 학습용 데이터가 인공지능 모델 학습에 들어가기 전에 문장 구조·형식이

49) 원시데이터의 노이즈란 인공지능 학습에 방해가 되는 불필요한 오류, 왜곡, 중복, 누락 등의 품질 저하 요소로, 인공지능이 제대로 학습하기 어렵게 만드는 데이터. (예) 인공지능에게 고양이 사진을 학습시키려고 하는데 사진이 너무 흔들렸거나, 고양이가 반쯤 가려져 있거나, 사진 안에 엉뚱한 글자·얼룩·중복 이미지가 섞여 있으면 인공지능이 제대로 학습하기 어려우므로 이를 제거하여 원천데이터 획득

50) 품질지표 중 ① 구축 공정 적정성은 [별표 2] “공공데이터 품질관리 지표”와 큰 차이가 없고, ② 데이터 적합성은 검사 방법이 체크리스트이거나 데이터에 따라 다르게 설정된다는 점에서 일관적인 품질 분석이 어려우며, ③ 인공지능 학습모델 적합성의 경우 데이터가 아닌 학습모델과 알고리즘의 유효성을 측정하므로 이번 분석에서 제외하고, ④ 가공데이터 정확성 중 구문 정확성 지표가 인공지능 모델이 데이터를 학습하기 전 데이터가 규칙대로 잘 만들어졌는지 확인하는 인공지능 모델 학습의 전제가 되는 품질지표이므로 이를 중심으로 분석

51) 데이터 가공 과정에서 인간이 부여한 식별 기준을 기계가 인식할 수 있도록 선정된 데이터에 추가적인 정보를 기입하여 알고리즘이 이해할 수 있도록 만드는 과정

52) 구문규칙규격서는 인공지능 학습용 데이터 라벨링 작성 양식과 규칙임

일관되게 맞춰져 있는지 [그림 6]과 같이 ① 무결성 검사, ② 구조 정확성 검사, ③ 형식 정확성 검사 절차를 거쳐 학습용 데이터의 품질수준을 검증한다.

[그림 6] 구문 정확성 지표 검사 절차^{주)}



주: 무결성 확인은 가공데이터가 읽기 실행 시 이상이 없는 경우에만 구조 정확성·형식 정확성에 대한 검사를 수행하고, 이상이 있는 경우는 검사를 중지하고 문제점을 확인 및 조치
자료: 지능정보사회원, 「AI 데이터 품질관리 가이드라인 v3.5」, 2025년 2월

가) 구문규칙규격서가 없어 구문 정확성 품질검증 실시 불가능

분석대상 기관 20개 중 중기부 등 13개 기관은 사업수행기관 자체기준 등을 이용해 품질 자가점검을 하고 있다고 응답하였으나, [표 25]와 같이 그중 5개 기관이 구축·공개한 학습용 데이터 114종 중 96종(84.2%)은 문장 구조·형식 등의 정확성을 판단하기 위한 구문규칙규격서 등이 없어 구문 정확성을 측정하는 구문검사 자체가 불가능해 구축한 인공지능 학습용 데이터의 품질측정을 할 수 없다.

[표 25] 인공지능 학습용 데이터 구문 정확성 검사 실시가 어려운 기관 현황

연번	기관명 (인공지능 학습용 데이터 수)	품질 자가점검 기준		구문규칙규격서 유무
		적용 기준	기준 마련 기관	
1	중기부 (49종)	「제조데이터 품질검증 가이드라인」	개대	×
2	개관 (48종)	「인공지능 학습용 데이터 품질관리 가이드라인」(6종)	지능정보사회원	○
		내부 기준 등(42종) ^{주)}	개관 사업수행기관	×
3	개관 (9종)	「공공데이터 품질관리 매뉴얼 v2.0」	행안부	×
4	한국광해광업공단 (5종)	「공공데이터 품질관리 매뉴얼 v2.0」	행안부	×
5	한국남부발전(주) (3종)	「합성데이터 생성·활용 안내서」	개보위	×
계(114종)				

주: 42종 중 12종은 구문규칙규격서가 있음

자료: 중기부 등 제출자료 재구성

나) 구문 정확성 품질 미흡

한편, 구문규칙규격서가 있는 2개 기관(경기도, 한국도로공사)의 학습용 데이터 6종⁵³⁾을 대상으로 품질검증 전문기관인 기술협회에 품질검증 용역을 의뢰하여 구문 정확성 검사를 실시한 결과, 다음과 같은 문제점을 확인하였다.

① 구문 정확성이 낮은 것으로 확인된 사례

「AI 데이터 품질관리 가이드라인 v3.5」에 따르면 구문 정확성 지표 설정 기준값은 99.5%이며 이는 전체 검사 대상 데이터의 구조 및 형식 오류가 각각 0.5%를 초과하지 않아야 구문 정확성 검사를 통과한다는 의미이다.

그런데 경기도에서 2024년 수요기관으로 참여하여 구축한 ‘자율운행 성능 고도화를 위한 해상환경 학습 데이터셋’의 경우 구문 정확성 지표 검사 절차 중 형식 정확성 검사(4단계) 결과값이 87.02%로 기준값인 99.5%에 미달하는 등 [표 26]과 같이 기술협회에 품질검증을 의뢰한 6종의 학습용 데이터 중 5종의 형식 정확성 결과값(77.32~99.17%)은 기준값인 99.5%에 미달하였고, 그중 한국도로공사에서 2023년 구축한 ‘차량종류 분류 학습데이터셋’과 2025년 구축한 ‘야생동물 종 분류 학습데이터셋(고라니)’은 구문 정확성 지표 검사 절차 중 구조 정확성 검사(3단계) 결과값(88.72%, 98.33%)도 기준값인 99.5%에 미달하였다.

[표 26] 인공지능 학습용 데이터 6종의 구문 정확성 검사 결과

(단위: %)

연 번	기관	데이터명	품질 자가점검	제3자 품질검증	구문 정확성 결과	
					구조 정확성	형식 정확성
1	경 기 도	교통 CCTV 인공지능 학습용 데이터	○	×	100	99.17
2		자율주행 및 ADAS 인공지능 학습용 데이터	○	○	100	94.11
3		자율운행 성능 고도화를 위한 해상환경 학습 데이터셋	○	×	100	87.02
4	한국	야생동물 종 분류 학습데이터셋(고라니)	○	×	98.33	90
5	도로 공사	도로주행 CCTV 학습데이터셋	○	×	확인 불가	확인 불가
6		차량종류 분류 학습데이터셋	○	×	88.72	77.32

자료: 기술협회 검사결과서 재구성

53) 예산상 한계로 구문규칙규격서가 있는 한국도로공사 등 2개 기관(6종)을 표본으로 구문 정확성 검사 실시

특히 ‘도로주행 CCTV 학습데이터셋’은 구문검사규칙 및 메타데이터 파일에 어노테이션 정보가 누락되어 있어 구문 정확성 검사가 불가능한 등 구문 정확성의 품질이 낮은데도 대부분 제3자 품질검증을 거치지 않은 채 개별포털(경기데이터드림, 고속도로 공공데이터 포털)에 그대로 공개되고 있었다.

② 어노테이션 정보 누락으로 구문 정확성 검사가 불가능한 사례

어노테이션은 데이터 가공 공정에서 인간이 부여한 식별 기준을 기계가 인식할 수 있도록 선정된 데이터에 추가적인 정보를 기입하여 알고리즘이 이해할 수 있도록 만드는 과정이다. 이에, 과기정통부가 구축하여 AI Hub에 공개 중인 학습용 데이터는 구문 정확성 지표 검사 절차 중 형식 정확성 검사(4단계)를 통해 어노테이션 파일을 구성하는 데이터가 형식 및 범위를 준수하는지 확인하도록 되어 있다.

그런데 한국도로공사가 2025년 구축한 ‘도로주행 CCTV 학습데이터셋’의 경우 구문검사규칙 및 메타데이터 파일에 어노테이션 정보가 누락되어 구조 및 형식 정확성 검사가 불가능한 것으로 확인되었다.

이를 구체적으로 살펴보면, [그림 7]과 같이 이미지(원천데이터) 2,680장⁵⁴⁾에 객체(자동차 등)를 표시하는 직사각형의 경계인 바운딩 박스⁵⁵⁾가 그려져 있는데, 이 경우 학습용 데이터를 설명하는 어노테이션 파일에 바운딩 박스의 위치 좌표 정보가 포함되어 있어야 인공지능이 학습을 할 때 직사각형 경계 안의 객체(자동차 등)를 인지할 수 있으나, ‘도로주행 CCTV 학습데이터셋’의 경우 어노테이션 파일에 바운딩 박스 위치 좌표 정보가 누락되어 있다.

54) 한편, 한국도로공사에서 작성한 메타데이터 구조표에는 데이터 구축량이 2,500장이라고 작성되어 있으나, 실제 원천데이터는 2,680장이며 메타데이터는 536개로 제시된 정보와 불일치

55) 바운딩 박스는 객체를 둘러싼 직사각형의 경계로, 4개의 모서리 좌표로 구성됨

[그림 7] 한국도로공사 ‘도로주행 CCTV 학습데이터셋’ 어노테이션 오류



자료: 기술협회 검사결과서 재구성

그 결과, ‘도로주행 CCTV 학습데이터셋’은 인공지능 모델을 학습시킬 수 없으며, 해당 데이터를 인공지능 모델 학습에 활용하기 위해서는 바운딩 박스의 좌표 정보를 다시 구축하거나, 이미지에 그려진 바운딩 박스를 별도로 추출하는 추가 작업이 필요한데도 한국도로공사는 이를 그대로 개별포털에 공개하고 있었다.

다) 품목명과 이미지 내용이 불일치한 JSON 파일 오류

인공지능 학습용 데이터는 [표 27]과 같이 텍스트 중심의 정형 데이터로 테이블과 칼럼 구조로 저장되는 데이터베이스 데이터와 달리 소리, 영상, 이미지 등 비정형 데이터 중심으로 정해진 폴더에 JSON 파일⁵⁶⁾ 형태로 저장된다.

[표 27] 인공지능 학습용 데이터와 데이터베이스(DB) 데이터의 비교

구분	인공지능 학습용 데이터	데이터베이스(DB) 데이터
구축 목적	• 인공지능 모델의 학습 목적	• 정보 검색 및 활용 목적
데이터 유형	• 소리, 영상, 이미지, 자연어 등 비정형 데이터 중심	• 텍스트 데이터 중심의 정형 데이터 중심
데이터 구조	• 원천데이터와 가공데이터가 쌍으로 구성	• 테이블과 칼럼으로 구성
데이터 구축절차	• 임무 정의→획득→정제→라벨링→학습→저장	• 수집→정제→변환→저장
데이터 관리방식	• 파일 형태로 저장(폴더+JSON 파일)	• 범용적인 DBMS ^{주)} 에 저장(테이블+칼럼 구조)

주: Database Management System

자료: 지능정보사회원, 「인공지능 학습용 데이터 품질관리 가이드라인 V1.0」, 2021년 2월

56) 데이터를 텍스트 파일 형식으로 정리해 둔 것(정답·설명·좌표 정보 등)을 말함

JSON 파일은 데이터를 저장하고 전송하기 위해 사용하는 구조화된 데이터 파일 형식 중 하나로 사람과 기계 모두 읽기 쉬운 텍스트로 저장되며, 웹·앱·API⁵⁷⁾ 등에서 서로 다른 시스템 간 데이터를 안정적으로 주고받는 표준으로 사용된다. 만약, 이미지(원천데이터)와 JSON 파일이 불일치하면 인공지능이 이미지를 불러오지 못하거나 표시오류가 발생한다.

이에, 과기정통부가 구축하여 AI Hub에 공개 중인 학습용 데이터는 구문 정확성 지표 검사 절차 중 구조 정확성 검사(3단계)를 통해 이미지(원천데이터)와 JSON 파일이 서로 연결되어 있고, 정해진 폴더 위치에 저장되어 있는지 확인하도록 되어 있다.

그런데 서울특별시가 공개 중인 인공지능 학습용 데이터(18종⁵⁸⁾) 중 2020년 구축된 ‘대형폐기물 학습데이터’(학습 대상 79종류, 이미지 수 2,303장)의 경우 일부 JSON 파일에 외관상 오류(원천데이터와 JSON 파일명 불일치)가 있어 대형폐기물 학습용 데이터 학습대상 이미지 전체 2,303장에 대해 JSON 파일과 실제 이미지(원천데이터)와의 일치 여부를 분석⁵⁹⁾하였다.

분석결과, 서울특별시는 대형폐기물 학습용 데이터 구축 시 제3자 품질검증을 통한 구조 정확성 검사(3단계)를 실시하지 않아, [표 28]과 같이 ‘대형폐기물 학습데이터’ 학습 대상 이미지 총 2,303장 중 538장(23.4%)의 JSON 파일과 실제 이미지(원천데이터)가 불일치하는데도 [그림 8]과 같이 그대로 개별포털(서울 열린데이터광장)에 공개하고 있었다.

57) Application Programming Interface, 프로그램 사이에 기능이나 데이터를 주고받는 연결규약

58) 서울특별시 구축 데이터 17종, 서울AI재단 구축 데이터 1종으로 총 18종

59) 감사원 자료분석시스템(BARON)을 통해 분석 후 서울특별시로부터 학습용 데이터의 오류에 대해 확인을 받았고, 서울특별시는 문제점을 개선한 후 공개하겠다는 의견 제출







[표 28] 서울특별시 '대형폐기물 학습데이터' 관련 JSON 파일과의 이미지 매칭률^{주)}

(단위: 장, %)

이미지 데이터 수	JSON 파일과의 일치 여부(매칭률)		
	일치	불일치	보류
2,303	1,663(72.2)	538(23.4)	102(4.4)

주: 육안으로 JSON 파일과 이미지의 일치 여부를 판단하였으며, 102장의 경우 구분이 모호하여 보류
자료: 서울특별시 제출자료 재구성

[그림 8] 서울특별시 '대형폐기물 학습데이터' 관련 JSON 파일과 다른 이미지(예시)

JSON 파일명	JSON 파일명과 일치하지 않은 이미지		
가방			
밥상			

자료: 서울특별시 제출자료 재구성

4. 소결

개별 공공기관에서 인공지능 학습용 데이터를 구축할 때 통일된 품질관리 기준이 없다면, 품질 자가점검 및 제3자 품질검증을 하지 않거나 부실하게 하는 등으로 인공지능 학습용 데이터의 구조적·형식적 오류나 규격 위반, 라벨 불일치 등의 문제를 충분히 걸러내지 못하게 되어 개별 공공기관별로 구축한 인공지능 학습용 데이터의 품질에 차이가 발생할 뿐만 아니라 낮은 품질의 데이터를 제공하게 되어 인공지능 모델 학습의 정확도를 크게 저해하는 요인으로 작용할 우려⁶⁰⁾가 있다.

60) 일부 개별 공공기관은 행안부의 AI 친화·고가치 데이터 개방 관련 평가지표에서 실적을 확보하는 데 중점을 두고, 해당 데이터가 실제 인공지능 학습용으로 활용 가능한 수준인지에 대한 충분한 품질검토 없이 데이터를 공개한 것으로 확인됨

따라서 인공지능 모델 성능 고도화를 위해서는 인공지능 학습용 데이터의 품질을 향상시키는 것이 필수적이므로 개별 공공기관이 구축·공개하는 인공지능 학습용 데이터의 품질이 향상될 수 있도록 인공지능 학습용 데이터의 특성을 고려하여 공통적으로 적용하는 품질관리 기준을 마련하거나 「AI 데이터 품질관리 가이드라인」을 활용하여 품질 자가점검 및 제3자 품질검증을 하는 등의 개선 방안을 마련할 필요가 있다.

5. 관계기관 의견

과기정통부는 공공기관이 개별적으로 구축하는 인공지능 학습용 데이터에 대한 품질검증 및 품질관리 필요성에 공감하면서, 기존 정부예산 사업을 통해 이미 산출된 인공지능 학습용 데이터는 전수조사를 통해 품질관리 여부를 포함하여 범부처 차원의 현황을 파악하여 품질을 검증하고, 미흡한 경우 데이터·인공지능 전문기업의 보완을 거쳐 등재할 계획이라고 하는 한편, 인공지능 학습용 데이터 전수조사 과정에서 각 부처들이 자체적으로 인공지능 학습용 데이터의 품질을 관리할 수 있도록 「AI 데이터 품질관리 가이드라인」에 대한 안내를 병행하고, 필요시 품질관리 컨설팅 등을 제공할 계획이라는 의견을 제시하였다.

나아가 정부예산 사업을 통해 산출될 인공지능 학습용 데이터에 대해서는 예산집행 시 각 부처가 자체적으로 품질관리를 실시하도록 기획예산처 등 관계 부처와 협의하여 예산 및 기금운용계획 집행지침 개정 등을 검토해 나가겠다는 의견을 제시하였다.

행안부도 감사원의 지적 취지에 공감하며, 그동안의 공공데이터 품질관리 체계는 공공기관에서 관리하는 공공데이터에 대해 적절한 품질수준 확보를 위해

공공데이터법 제22조 및 같은 법 시행령 제17조에 근거하여 각 기관의 정보시스템 DB 데이터의 정확성과 완전성 등을 확보하고자 하였으나, 인공지능 시대에 맞춰 공공데이터의 AI 검색 및 활용에 용이하도록 데이터 포맷, 메타데이터 정보, 표준코드, 품질 속성 등의 기준을 제시하는 ‘공공데이터의 인공지능 친화적 관리를 위한 가이드라인’을 준비하고 있으며, 향후 공공기관이 인공지능 학습용 데이터 구축사업을 추진할 때 해당 가이드라인을 기준으로 품질관리 등을 할 수 있도록 권고하고, 평가체계 등을 개선하며, 인공지능 기술에 맞게 해당 가이드라인도 개선해 나갈 예정이라는 의견을 제시하였다.

조치할 사항 과학기술정보통신부장관은 행정안전부장관과 협의하여 개별 공공기관이 구축·공개하는 인공지능 학습용 데이터의 품질수준이 향상될 수 있도록 공통적으로 적용하는 품질관리 기준을 마련하거나 최신의 「AI 데이터 품질관리 가이드라인」을 적용하여 품질 자가점검 및 제3자 품질검증을 하도록 하는 등의 방안을 마련하시기 바랍니다.(통보)

제4절 학습용 데이터 사후관리 분야

3 데이터 구축 사업수행기관 폐업 시 사후관리 방안 미흡

1. 업무 개요

지능정보사회원은 지능정보화법 제12조에 따라 지능정보사회 관련 정책의 개발과 국가기관 등의 지능정보사회 시책 및 지능정보화 사업의 추진 등을 지원하기 위하여 설립되어 국가기관 등의 지능정보화 사업 추진 및 평가 지원 업무를 수행하고 있다.

가. 인공지능 학습용 데이터 구축 및 공개

지능정보사회원은 「초거대 인공지능 생태계 조성 사업 관리지침」(내부 지침) 등에 따라 인공지능 기술 및 서비스 개발에 필수적인 학습용 데이터 구축을 위해 매년 민간 기업 등으로 구성된 컨소시엄(주관기관과 참여기관으로 구성)을 사업수행기관으로 선정하여 협약을 체결하고 사업비를 지원하고 있는데, 2017년부터 2024년까지 구축된 인공지능 학습용 데이터는 총 908종⁶¹⁾으로 이를 누구나 활용할 수 있도록 AI Hub에 등록하여 대외에 공개하고 있다.

나. 인공지능 학습용 데이터 공개 이후 사후관리

지능정보사회원은 사업 종료 후에도 일정 기간(1~5년)을 학습용 데이터 사후관리 기간으로 설정하여 사업수행기관이 해당 기간 내 발생하는 학습용 데이터의 오류를 무상으로 수정·보완하고 이용자 민원에 대응하도록 하고 있다.

사후관리 체계는 크게 두 단계로 나뉘는데, 사업 종료 후 1년까지는 소프트웨어법 제60조 등에 따른 하자담보책임 기간으로 수행기관이 하자 보수 불이행 시

61) 2024년 말까지 총 903종을 구축하고 그중 12종은 각각 2종으로 분리·공개하여 총 915종을 공개하였으나 7종은 데이터 재검증을 위해 공개를 중단 중이며 2025년 11월 기준 908종을 공개 중이므로 구축된 데이터를 908종으로 실시

보험금 청구 등을 통해 이행 담보력이 확보된다. 이와 별도로 학습용 데이터 구축사업 종료 후 5년까지는 협약서 특약조건 제4조 및 제13조 등에 따른 성과 활용기간으로 별도의 보증금 등이 없이 사업수행기관의 협약상 의무 이행에 기반하여 사후관리가 이루어지고 있다.

한편, 협약서 특약조건 제13조 등에 따르면 사업수행기관은 원본데이터뿐만 아니라 학습용 데이터 구축 사업을 수행하며 생성된 가공데이터(라벨링데이터), 인공지능 응용모델 소스, 저작도구⁶²⁾, 각종 매뉴얼 등(이하 “구축 산출물”이라 한다)을 함께 AI Hub에 등록하도록 하고 있어, 학습용 데이터를 구축한 사업수행기관이 폐업 등의 사유로 하자 보수를 할 수 없는 경우 구축 산출물 등을 활용해 제3자를 통한 하자 보수도 가능하다.

2. 감사접근 방법

인공지능 학습용 데이터의 오류는 인공지능 모델 학습의 정확도와 성능을 떨어뜨리는 요인으로 작용하므로 학습용 데이터의 신뢰성을 확보하기 위해서는 사업수행기관 폐업 등으로 유지보수 공백이 발생하였을 때 주관기관 또는 참여기관 중 잔존 기관 또는 제3자로 하여금 구축 산출물 등을 활용하여 즉시 오류를 보수하도록 하는 등의 사후관리가 중요하다.

이와 관련하여 지능정보사회원은 「ICT 기금사업 및 연구개발사업 관리지침」(내부 지침)상 표준협약서(협약서 제4조, 특약조건 제19조) 등에 따라 학습용 데이터 구축 사업을 수행하는 컨소시엄 구성 기관들(주관기관과 참여기관)로 하여금 협약상 의무를 연대하여 이행하도록 하는 한편, 협약을 위반하여 지능정보사회원에

62) 인공지능이 학습할 수 있도록 데이터(텍스트, 영상, 이미지 등) 위에 설명이나 주석 등을 쉽게 편집할 수 있도록 지원하는 프로그램

손해를 끼쳤을 때에도 연대하여 책임지도록 하고 있다.

하지만, 법적 하자담보책임 기간(1년)이 경과한 성과활용기간(2~5년 차) 내에 사업수행기관 일부, 특히 주관기관이 폐업할 경우 컨소시엄을 구성했던 나머지 참여기관들은 연대책임을 기피할 우려가 있고, 잔존 사업수행기관이 하자 보수를 거부할 경우 현실적으로 지능정보사회원 또한 이들 기관에 의무 이행을 강제하거나 실효성 있는 제재를 가하기 어려워⁶³⁾ 학습용 데이터의 사후 품질관리가 제대로 이루어지지 않을 가능성이 높다.

이에, 사업수행기관(주관기관과 참여기관)의 폐업 현황과 폐업 이후 학습용 데이터 관련 이용자의 민원 확인 및 대응실태 등을 통해 ① 사업수행기관 폐업을 사유로 이용자 민원이 별도의 조치 없이 종결 처리되고 있지 않은지, ② AI Hub에 등록된 구축 산출물 등을 활용하여 이용자 민원 대응 및 학습용 데이터 품질관리를 제대로 하고 있는지 등 학습용 데이터 구축 이후 사후관리 실태를 점검할 필요가 있었다.

3. 감사결과 확인된 문제점

가. 분석대상 및 범위

이번 감사에서는 성과활용기간이 5년으로 확대⁶⁴⁾된 2021년 이후부터 2024년 말까지 구축되어 공개 중인 학습용 데이터 721종⁶⁵⁾과 해당 학습용 데이터 구축 사업에 참여한 1,270개⁶⁶⁾ 사업수행기관을 주요 분석 대상으로 설정⁶⁷⁾하였다.

63) 성과활용기간에 데이터 오류 발생 시 사업수행기관으로 하여금 수정·보완하도록 하고 있으나, 미이행 시 강제할 수단은 없음

64) 지능정보사회원은 기존 3년으로 설정하였던 성과활용기간을 2021년부터 5년으로 확대

65) 2025년 구축 데이터는 아직 공개되지 않아 제외

66) 2021~2024년 구축 사업에 참여한 전체 기관 중 동일 기업이 복수의 과제에 주관 또는 참여기관으로 중복 참여한 경우를 제외한 기업 수

67) 분석대상 학습용 데이터들은 2026년 1월 기준으로 사업 종료 후 1년이 경과하여 하자담보책임 기간이 종료된 상태

먼저, 국세청의 ‘사업자등록정보 진위확인 및 상태조회 서비스’를 통해 인공지능 학습용 데이터 구축 사업수행기관의 폐업 현황을 전수 조사하고 이들이 구축한 학습용 데이터 현황을 파악하였다.

이후, 해당 폐업 업체의 명단을 AI Hub 민원 대응 자료와 대조하여, 최근 3년간(2023~2025년) 접수된 오류 신고 및 기술 문의 등 인공지능 학습용 데이터 이용자의 민원이 사업수행기관의 존속 여부에 따라 어떻게 처리되고 있는지 그 실태를 분석하였다.

나. 분석결과

2021년부터 2024년까지 인공지능 학습용 데이터 구축 사업을 수행한 1,270개 업체(주관기관 또는 참여기관)에 대하여 국세청 사업자등록상태(2026. 1. 6. 기준)를 전수 조사한 결과, 총 62개 업체(4.9%)가 폐업한 것으로 확인되었다.

또한, 지능정보사회원 자체확인 결과 폐업 절차를 진행 중이거나 구축사업 담당자 퇴사 및 업종 변경 등 내부 사정으로 이용자 민원 대응 및 인공지능 학습용 데이터 유지보수 업무 수행이 불가능한 업체 3곳(0.2%)이 추가로 파악되었다.

AI Hub에 공개 중인 학습용 데이터 중 폐업한 62개 업체와 폐업절차 진행 등 내부 사정이 발생한 3개 업체 등 계 65개 업체(주관기관 17개, 참여기관 48개)가 구축한 학습용 데이터는 [표 29]와 같이 213종(주관기관 관련 66종, 참여기관 관련 147종)에 달하며, 이는 분석대상 전체(721종) 학습용 데이터의 29.5%에 해당한다.

[표 29] 사업수행기관 폐업 및 관련 학습용 데이터 구축 현황

(단위: 개, 종, %)

구 분	분석 대상 (A)	현재 폐업 또는 내부 사정 발생 업체			비중 (B/A)
		주관기관	참여기관	계 (B)	
업체 수	1,270	17	48	65	5.1
학습용 데이터	721	66	147	213	29.5

자료: 지능정보사회원 제출자료 및 국세청 조회 결과 재구성

1) 주관기관 폐업의 경우

☐☐는 주관기관으로서 2021. 12. 31. ‘다국어 구어체 번역 병렬 말뭉치 데이터’(정부출연금 30억 원)를 구축한 후 2022. 3. 31. 폐업하는 등 [별표 3] “인공지능 학습용 데이터 구축 주관기관의 폐업 등 현황”과 같이 17개 주관기관이 학습용 데이터 66종을 구축한 이후 폐업하였다.

그런데 지능정보사회원은 17개 폐업 주관기관이 구축하여 AI Hub를 통해 공개 중인 학습용 데이터 66종 중 ‘지자체 도로정비 AI 학습용 데이터’(주관기관: ☐☐) 등 7종에 대해 [별표 4] “폐업한 주관기관의 학습용 데이터 관련 민원 접수 및 처리 현황”과 같이 하자 보수 요청 등의 민원이 발생하였는데도 주관기관의 폐업 등으로 적기에 유지보수 등의 대응을 할 수 없다는 내용으로 민원을 종결 처리만 할 뿐 오류에 대하여 구축 산출물 등을 활용하여 직접 또는 제3자를 통한 하자 보수를 하지 않은 채 2025년 12월 현재까지 AI Hub에 그대로 공개하고 있다.

특히, 지능정보사회원은 ‘지역안전재난(산불) 방재의 고도화를 위한 대규모 인공지능 데이터베이스 구축’(주관기관: ☐☐)의 경우 [표 30]과 같이 학습용 데이터 해제 과정에서 오류가 발생한다는 민원이 세 차례(2025. 8. 3.자 2건 포함) 제기되었고, 이에 대해 학습용 데이터 일부가 누락되어 있는 것을 확인하고도 사업 수행기관의 폐업과 담당자 퇴사 등을 사유로 별도⁶⁸⁾의 보완 조치 없이 민원을 종결 처리하고, 해당 학습용 데이터를 2025년 12월 현재까지 AI Hub에 그대로 공개 중에 있다.

68) 지능정보사회원은 민원 접수 시 수행기관에 이메일 등으로 연락을 시도한 후 폐업 등으로 연락이 안 될 경우 민원인에게 내부 사정 등으로 대응이 어렵다는 취지의 답변을 회신함

[표 30] 폐업한 주관기관의 학습용 데이터 관련 민원 내역

주관기관 (데이터명)	민원 날짜	민원 내용	대응 내용	종결 사유
가아 [지역안전재난(산불) 방재의 고도화를 위한 대규모 인공지능 데이터베이스 구축]	① 2025. 8. 3.	데이터 압축 해제 과정에서 오류 발생 등 2건의 민원 접수	실제 확인 결과, 제공된 파일 내 일부 파일이 비어 있는 상태로 확인되었으나 수행기관은 현재 폐업 상태로 파일의 원본 구성의 정확한 경위 확인이 어려움	폐업 등 내부사정
	② 2025. 8. 11.	Failed to ingest 등 에러 발생	도커 이미지 내 일부 layer가 정상적으로 구성되지 않아 발생하는 현상으로, 제공된 파일 내 일부 파일이 비어 있는 상태로 확인되었으나 해당 기관은 폐업 상태로 해당 구성의 정확한 경위 확인이 어려움	

자료: 지능정보사회원 제출자료 재구성

2) 참여기관 폐업의 경우

한편, 가자(가자)는 2021년 참여기관으로서 ‘저음질 전화망 음성인식 데이터’(정부출연금 15억 원)의 구축(주관기관: 가자)에 참여(데이터 품질 관리 담당)한 후 2024. 12. 17. 폐업하는 등 48개 참여기관이 학습용 데이터 147종의 구축에 참여한 후 폐업하였다.

그런데 지능정보사회원은 폐업한 48개 참여기관이 구축에 참여하여 AI Hub를 통해 공개 중인 학습용 데이터 147종 중 ‘저음질 전화망 음성인식 데이터’(참여기관: 가자) 등 4종에 대해 [별표 5] “폐업한 참여기관의 학습용 데이터 관련 민원 접수 및 처리 현황”과 같이 하자 보수 요청 등의 민원이 발생하였는데도, 주관기관 등 잔존 기관으로 하여금 구축 산출물 등을 활용하여 이용자 민원 대응 및 하자 보수를 하도록 요구하거나 제3자를 통한 하자 보수 등 학습용 데이터 품질을 보존하려는 실효성 있는 조치 없이 “참여기관의 폐업 또는 내부 사정으로 인해 답변 및 수정이 불가능하다”는 취지로 회신한 후 민원을 종결 처리하고 있었다.

특히, ‘저음질 전화망 음성인식 데이터’(참여기관: 개자)의 경우, 지능정보사회원은 [표 31]과 같이 2023년 1월 데이터 품질 문제로 민원을 접수하고 같은 해 3월 해당 학습용 데이터에 대한 보완조치 후 재등록하였으나, 2025년 2월 다시 데이터 매칭 결함이 다수 존재한다는 민원을 접수하였다. 그러나 지능정보사회원은 이에 대해 해당 구축 업체의 내부 사정⁶⁹⁾으로 추가적인 수정·보완이 불가능하다고 답변하며 민원을 종결 처리한 후, 2025년 12월 현재까지 해당 데이터를 AI Hub에 그대로 공개하고 있다.

[표 31] 폐업한 참여기관의 학습용 데이터 관련 민원 내역

참여기관 (데이터명)	민원 날짜	민원 내용	대응 내용	종결 사유
■ <u>개자</u> (저음질 전화망 음성인식 데이터)	① 2023. 1. 6.	■ 데이터 품질 문제 발견	■ 2023년 3월 데이터 보완조치 후 재등록	참여기관 폐업
	② 2025. 2. 19.	■ 많은 데이터가 전사와 음성이 매칭되지 않음	■ 데이터의 수정·보완은 구축 수행기관만 가능하나, 해당 업체의 내부 사정 등으로 추가적인 수정·보완은 어려움	
■ <u>개자</u> (에세이 글 평가데이터)	① 2025. 4. 30.	■ 문장이 동일한 글이 다수 존재	■ 동일한 제시문을 바탕으로 작성된 글이기 때문에 일부 문장이나 표현이 유사할 수 있음	참여기관 폐업
	② 2025. 5. 1.	■ 띄어쓰기·맞춤법 오타까지 동일한 데이터가 다수 존재	■ 데이터 내에 동일하거나 유사한 문장이 포함된 사례를 확인하였으나, 지능정보사회원은 수행기관의 폐업으로 추가적인 정정이나 보완이 어렵고, 유사하거나 중복된 항목이 포함되어 있을 수 있음을 감안하여 사용하길 권장	

자료: 지능정보사회원 제출자료 재구성

더욱이, 지능정보사회원은 ‘에세이 글 평가 데이터’(참여기관: 개자)의 경우에 [표 31]과 같이 2025년 4월 학습용 데이터 내에 중복 데이터가 다수 포함되어 있다는 민원이 제기되었으나, 한 차례 문제가 없다고 답변하였다가, 이후에 다시 민원이 제기되자 동일·유사 문장이 포함된 오류 사례가 있음을 확인하였다.

하지만, 지능정보사회원은 사업수행기관(참여기관)의 폐업으로 추가적인

69) 이메일·유무선으로 연락을 시도하여 사업수행기관으로부터 담당자 퇴사 등의 내부 사정으로 답변이 어렵다는 것을 회신받은 후 민원인에게 해당 사실을 안내

정정이나 보완이 어렵고, 민원인에게 유사하거나 중복된 항목이 포함되어 있을 수 있음을 감안하여 사용하길 권장한다고 답변하며 후속 조치 없이 2025년 12월 현재까지 AI Hub에 그대로 공개하고 있다.

4. 소결

이와 같이 지능정보사회원은 폐업한 사업수행기관이 구축한 학습용 데이터의 오류가 확인되었는데도 사업수행기관 등의 폐업 등으로 데이터 수정·보완이 불가능하다고 답변하며 민원을 종결 처리할 뿐 오류가 포함된 학습용 데이터를 AI Hub에 그대로 공개하고 있어, 이를 활용해 학습하는 인공지능 모델 학습의 정확도와 성능을 떨어뜨리는 요인으로 작용할 우려가 있다.

따라서 폐업 등으로 사업수행기관을 통한 사후관리가 불가능한 인공지능 학습용 데이터에 대해서는 AI Hub에 등록된 구축 산출물 등을 활용하여 지능정보사회원에서 직접 민원에 대응하거나 제3자 유지보수 체계를 구축하는 등 학습용 데이터의 신뢰성을 확보하기 위한 실효성 있는 사후관리 방안을 마련할 필요가 있다.

참고로, 국립국어원은 2019년부터 인공지능 학습을 위한 한국어 말뭉치 구축 사업을 수행하여 2025년 기준으로 총 119종의 학습용 데이터를 ‘모두의 말뭉치’(kli.korean.go.kr/corpus)에 공개하고 있는데, 법적 하자담보책임 기간(1년) 경과 이후 데이터 오류 등에 대한 민원이 발생하면 국립국어원 자체 인력으로 검수 후 보완작업을 거쳐 재공개하고 있다.

5. 관계기관 의견

지능정보사회원은 법적 하자담보책임 기간(1년)이 지나 확인된 데이터 하자 보수를 위해 유지보수 예산을 확보하고 AI Hub 운영 사업 내에 하자 보수 업무를 포함하는 한편, 해외 개발자 커뮤니티 사례와 같이 사용자가 발견한 오류를 수정·제안할 수 있는 오픈소스 기여 방식 도입을 검토하는 등 상시 조치 방안을 마련하여 오류가 확인되는 학습용 데이터를 개선해 나겠다는 의견을 제시하였다.

조치할 사항 한국지능정보사회진흥원장은 폐업 등으로 사업수행기관을 통한 사후관리가 불가능한 데이터에 대해서는 예산을 확보하여 AI Hub에 등록된 가공데이터, 인공지능 응용모델 소스, 저작도구 등을 활용하여 직접 오류를 수정하거나 제3자 유지보수 체계를 구축하는 등 인공지능 학습용 데이터의 신뢰성 확보를 위한 실효성 있는 사후관리 방안을 마련하시기 바랍니다.(통보)

제4장 종합 결론

제1절 감사결과 총평

최근 인공지능 기술은 범용 기술로서 전통적인 의미의 정보통신 분야뿐만 아니라 제조업과 금융, 물류 등 각 분야의 생산성과 효율성을 높일 수 있다는 특징이 있어 기술 선점을 위한 국가 간 경쟁이 치열하게 전개되고 있다.

이에 정부는 고품질의 인공지능 학습용 데이터를 구축·공개하여 인공지능 강국 도약 및 인공지능 주권을 확보하고자 2017년부터 2024년까지 1조 6,328억 원의 예산을 투입하여 총 908종의 데이터를 구축하고 AI Hub에 공개하는 등 인공지능 확산 생태계를 조성하기 위해 노력하고 있다.

그런데 이번 감사에서 ① 학습용 데이터 구축계획, ② 학습용 데이터 품질 관리, ③ 학습용 데이터 사후관리 등 3개 분야로 나누어 정부의 인공지능 학습용 데이터 구축사업 추진 실태를 점검한 결과 다음과 같은 문제점이 확인되었다.

첫째, 학습용 데이터 구축계획의 경우 과기정통부는 공공기관이 학습용 데이터를 새로 구축할 때 기존 데이터와의 유사성 및 대체 활용 가능성을 사전에 검토할 수 있는 기준과 절차를 마련하지 않아 개별 공공기관이 다른 공공기관에서 이미 구축한 데이터가 존재하는지 여부 자체를 확인하지 못하거나 구축 전 단계에서 개별 공공기관 간 데이터 구축계획이 충분히 공유·조정되지 않음으로써 유사한 학습용 데이터를 구축한 사례가 발생하는 등 공공재원의 효율적 집행을 저해하고 있었다.

둘째, 학습용 데이터 품질관리의 경우 과기정통부가 구축하여 AI Hub에 공개 중인 학습용 데이터는 「AI 데이터 품질관리 가이드라인 v3.5」가 적용되고 데이터

품질 전문기관인 기술협회의 제3자 품질검증을 받도록 하고 있어 일정 수준의 데이터 품질 수준을 확보하고 있는 반면, 개별 공공기관이 개별적으로 구축한 학습용 데이터는 기관별로 상이한 품질 점검기준을 적용하고 품질검증도 제3자가 아니라 자체적으로 하고 있어 인공지능 학습용으로 활용하기 어려운 저품질의 데이터가 구축되고 있었다.

마지막으로 학습용 데이터 사후관리의 경우 지능정보사회원은 AI Hub 이용자로부터 학습용 데이터에 대해 데이터 수정 등 민원을 접수하고 왜곡된 학습용 데이터를 확인하고도 데이터를 구축한 사업수행기관(주관기관, 참여기관)의 폐업 등을 사유로 데이터 수정이 불가능하다고 회신하며 민원을 종결 처리하고 있었다.

제2절 감사의 기대효과 및 한계

1. 감사의 기대효과

정부는 2017년부터 고품질의 인공지능 학습용 데이터를 구축하여 AI Hub에 공개하는 등 인공지능 확산 생태계를 조성하기 위해 노력해 오고 있으나, 인공지능 기업은 여전히 쓸 만한 데이터 확보가 어렵다고 지속적으로 호소하는 등 인공지능 강국으로 도약하기 위해서는 학습용 데이터의 품질 개선이 시급하다는 비판도 함께 제기되어 왔다.

이에 따라 인공지능 학습용 데이터의 구축 과정 및 품질관리 등의 실태를 점검하여 인공지능 기업이 체감할 수 있는 개선 대안을 제시할 목적으로 실시된 이번 감사를 통해 공공재원의 효율적 집행에 있어서 개별 공공기관의 학습용 데이터 구축계획, 학습용 데이터 품질관리, 학습용 데이터 사후관리 등과 관련하여

제도적 개선이 필요한 문제점이 확인되었다.

이번 감사로 인해 정부가 인공지능 개발 등을 지원할 목적으로 추진 중인 학습용 데이터 구축사업이 ① 기존 학습용 데이터의 대체 활용 가능성 등이 사전에 검토·조정되어 한정된 공공재원이 효율적으로 집행되고, ② 개별 공공기관이 구축하는 학습용 데이터에 통일된 품질관리 기준이 적용되며, ③ 실효성 있는 사후관리 방안이 마련되는 등으로 개선되어 더욱 쓸 만하고 풍부한 학습용 데이터가 인공지능 기업 등에 제공됨으로써 우리나라의 인공지능 경쟁력이 향상되는 계기가 될 것으로 기대한다.

2. 감사의 한계

이번 감사는 당초 전체 학습용 데이터 구축계획부터 학습용 데이터 품질관리, 학습용 데이터 사후관리까지 사업의 전 과정을 대상으로 체계적인 분석 및 점검을 하고자 하였으나 감사인력의 한계 등을 고려하여 공공재원의 효율적 집행 측면에서의 유사 데이터 구축 사례, 제3자 품질검증이 아닌 자가검증으로 인해 낮은 품질의 데이터가 구축되었을 우려가 있는 개별 공공기관의 학습용 데이터 등을 위주로 점검하였으므로 인공지능 학습용 데이터 전체에 대한 포괄적인 감사로 보기는 어렵다.

또한, 과기정통부의 인공지능 학습용 데이터 구축사업과 별도로 개별 공공기관이 구축한 학습용 데이터의 경우 이번 감사기간 중 감사원이 실시한 실태조사에 공공기관이 자체적으로 응답한 자료를 기초로 파악된 것으로서 일부 학습용 데이터의 누락 등이 있을 수 있어 향후 과기정통부에서 각 부처 및 공공기관이 보유한 인공지능 학습용 데이터 보유 현황을 체계적으로 파악하고, 인공지능 활용이 가능한 고품질 데이터 확보 기반을 마련하기 위해 지속적으로 노력할 필요가 있다.

별표 목차

[별표 1] 개별 공공기관별 품질관리 기준 및 품질검증 현황	62
[별표 2] 공공데이터 품질관리 지표	63
[별표 3] 인공지능 학습용 데이터 구축 주관기관의 폐업 등 현황	64
[별표 4] 폐업한 주관기관의 학습용 데이터 관련 민원 접수 및 처리 현황	67
[별표 5] 폐업한 참여기관의 학습용 데이터 관련 민원 접수 및 처리 현황	69

[별표 1]

개별 공공기관별 품질관리 기준 및 품질검증 현황

연 번	기관명 (AI 학습용 데이터 수)	품질관리 기준		자가점검	제3자 품질검증
		적용 기준	기준 마련 기관		
1	개보위 (2종)	「인공지능 학습용 데이터 품질관리 가이드라인」 「합성데이터 생성 참조모델」	지능정보사회원 개보위	실시	실시
2	공정위 (14종)	「인공지능 학습용 데이터 품질관리 가이드라인」	지능정보사회원	실시	실시
3	청주시 (1종)	「인공지능 학습용 데이터 품질관리 가이드라인」	지능정보사회원	실시	실시
4	그랜드코리아레저(주) (1종)	「인공지능 학습용 데이터 품질관리 가이드라인」	지능정보사회원	실시	실시
5	개관 (48종)	「인공지능 학습용 데이터 품질관리 가이드라인」(6종)	지능정보사회원	실시	실시(17종)
		내부 기준 등(42종)	개관 사업수행기관		미실시(31종)
6	국립국어원 (119종)	국립국어원 자체 전자 지침 및 가이드라인	국립국어원	실시	실시
7	중기부 (49종)	「제조데이터 품질검증 가이드라인」	개관	실시	실시
8	한국남부발전(주) (3종)	「합성데이터 생성·활용 안내서」	개보위	실시	실시
9	건강보험심사평가원 (10종)	정보화계획	사업수행기관	실시	실시(4종)
					미실시(6종)
10	한국광해광업공단 (5종)	「공공데이터 품질관리 매뉴얼 v2.0」	행안부	실시	실시
11	국토안전관리원 (5종)	「공공데이터 품질관리 매뉴얼 v2.0」	행안부	실시	미실시
12	개관 (9종)	「공공데이터 품질관리 매뉴얼 v2.0」	행안부	실시	미실시
13	서울특별시 (17종)	사업수행기관 기준(16종)	사업수행기관	실시	미실시
		연구기관 기준(1종)	연구기관(대학교)	실시	
14	서울AI재단 (1종)	사업수행기관 기준	사업수행기관	실시	미실시
15	한국도로공사 (16종)	사업수행기관 기준	사업수행기관	실시	미실시
16	한국저작권위원회 (1종)	사업수행기관 기준	사업수행기관	실시	미실시
17	경기도 (3종)	없음		실시	실시(1종)
					미실시(2종)
18	한국형사·법무정책연구원 (1종)	없음		실시	미실시
19	식약처 (1종)	없음		미실시	미실시
20	한국동서발전(주) (1종)	없음		미실시	미실시
계(307종)		품질관리 기준이 없는 기관 4개		실시 18개 미실시 2개	실시 11개 미실시 9개

주: 1. 중복 응답 가능(동일 기관에서 일부는 실시, 일부는 미실시한 경우 실시한 것으로 정리)

2. 경기도와 한국형사·법무정책연구원은 품질관리 기준은 없으나 자체 측정 지표 등으로 품질 자가점검을 실시하였다고 주장하여 자가점검 실시로 분류

자료: 개보위 등 제출자료 재구성

[별표 2]

공공데이터 품질관리 지표

품질지표	설명	세부 지표
준비성	공공데이터의 품질관리를 위해 기본적으로 관리해야 하는 정책, 규정, 조직, 절차 등을 마련하고, 최신의 내용으로 충실하게 관리되는지를 측정하는 지표	- 관리지표 - 내용충실
완전성	공공데이터의 저장소인 데이터베이스를 구축함에 있어 논리적인 설계와 물리적인 구조를 갖추고, 업무요건에 맞게 데이터가 저장되는지를 측정하는 지표	- 논리모델 - 식별자 - 물리구조 - 속성의미
일관성	같은 의미를 갖는 데이터는 논리적 속성 단위, 물리적 칼럼 단위에서 일관된 이름과 형식을 갖도록 표준을 준수하고 있는지, 공공데이터의 공동 활용을 위해 공유·연계하는 데이터는 누락이 없이 상호 간의 일관성을 유지하는지를 측정하는 지표	- 속성 - 표준 - 중복값 - 연겟값
정확성	정확한 데이터 제공을 위해 데이터의 입력 단계부터 오류가 입력되지 않도록 하고, 저장된 데이터가 정의된 기준에 맞게 유효한 값의 범위와 형식으로 되어 있는지, 저장된 데이터가 현실에 가장 가까운 최신 값을 반영하고 있는지를 측정하는 지표	- 입력값 - 업무규칙 - 범위·형식 - 참조관계 - 계산식
보안성	지속적인 품질확보를 위해 운영되는 데이터의 관리 주체가 관리되고 있는지, 권한에 따른 데이터 접근이 적절히 통제되고 개인정보 등 중요 데이터에 대해서는 암호화 등 보안 조치가 이루어져 있는지를 측정하는 지표	- 오너십 - 접근제한 - DB보호
적시성	사용자가 만족하는 수준의 응답시간이 확보되고 있는지, 사용자의 데이터 요구에 따른 수집·처리·제공까지의 절차가 체계적으로 관리되고 있는지를 측정하는 지표	- 응답시간 - 데이터제공 - 최신값
유용성	사용자가 만족하는 수준의 충분한 정보가 제공되고 있는지, 정보 접근 시 사용자의 편의성이 확보되고 있는지, 사용자의 정보 이용에 따른 만족 수준을 높이도록 노력하고 있는지를 측정하는 지표	- 충분 - 접근 - 활용

자료: 지능정보사회원, 「공공데이터 품질관리 매뉴얼 v2.0」, 2018년 1월

[별표 3]

인공지능 학습용 데이터 구축 주관기관의 폐업 등 현황

(단위: 억 원, 건)

연번	데이터명	정부출연금	주관기관명	데이터 구축일	폐업일	다운로드 수 ^{주)}
1	다국어 구어체 번역 병렬 말뭉치 데이터	30	개배	2021. 12. 31.	2022. 3. 31.	664
2	대규모 구매도서 기반 한국어 말뭉치 데이터	14	개배	2021. 12. 31.	2022. 3. 31.	2,644
3	대용량 손글씨 OCR 데이터	30	-	2021. 12. 31.	2025. 3. 17.	1,376
4	고서 한자 인식 OCR 데이터					227
5	커넥티드 항만을 위한 물류 인프라 데이터	15	-	2021. 12. 31.	2025. 3. 17.	199
6	과적차량 도로 위험 데이터	15	-	2021. 12. 31.	2024. 6. 7.	614
7	토지 피복지도 항공위성 이미지 데이터(경상)	30	-	2021. 12. 31.	2025. 6. 5.	238
8	토지 피복지도 항공위성 이미지 데이터(전라)					195
9	토지 피복지도 항공위성 이미지 데이터(제주도)					436
10	지자체 도로 정비 AI 학습용 데이터	14	개사	2021. 12. 31.	2024. 5. 31.	772
11	실내 공간 3D 종합 데이터	15	-	2021. 12. 31.	업종 전환	535
12	눈, 비, 안개 등의 다양한 외부 환경 노이즈 제거를 위한 영상 데이터	30	-	2021. 12. 31.	폐업 진행 중	586
13	Inpainting 자동화를 위한 영상 데이터					505
14	물류창고 내 작업 안전 데이터	30	-	2021. 12. 31.	폐업 진행 중	1,181
15	고소작업 현장 실시간 영상 데이터					1,345
16	자연 및 인공적 발생 자연어적 소리 데이터	14	-	2021. 12. 31.	폐업 진행 중	1,014
17	서울시 노후 주택 균열 데이터	14	-	2021. 12. 31.	폐업 진행 중	1,001
18	지역 안전재난(산불) 방재의 고도화를 위한 대규모 인공지능 데이터베이스 구축	11	개아	2022. 12. 31.	담당직원 퇴사로 대응 불가	1,116
19	가구·가전·사무기기 사용 모션 캡처 데이터	28	-	2022. 12. 31.	업종 전환	178
20	대화·발표 동작 모션캡처 데이터					361
21	한국 골목길 이미지 및 3D 데이터	29	-	2022. 12. 31.	업종 전환	318
22	문화유산 유적 3D 데이터					298

연번	데이터명	정부출연금	주관기관명	데이터 구축일	폐업일	다운로드 수 ^{주)}
23	객체 폐색 데이터	56	-	2022. 12. 31.	폐업 진행 중	254
24	훼손 및 블러링 데이터					379
25	저조도 환경 데이터					484
26	화질 변환 영상 데이터					395
27	상용 자율주행차 주간 도심도로 데이터	69	-	2022. 12. 31.	폐업 진행 중	288
28	상용 자율주행차 야간 도심도로 데이터					277
29	상용 자율주행차 주간 자동차 전용도로 데이터					266
30	상용 자율주행차 야간 자동차 전용도로 데이터					255
31	상용 자율주행차 악천후 데이터					238
32	지능형 인프라 센서 기반 동적 객체 인지 데이터	28	-	2022. 12. 31.	폐업 진행 중	323
33	노변기지국 송·수신 V2X 메시지 데이터					233
34	CCTV 기반 차량정보 및 교통 정보 계측 데이터	20	-	2022. 12. 31.	폐업 진행 중	4,060
35	가려진 객체 추론 데이터	14	-	2022. 12. 31.	폐업 진행 중	217
36	일상생활 작업 및 명령 수행 데이터(공간)	37	-	2022. 12. 31.	폐업 진행 중	160
37	일상생활 작업 및 명령 수행 데이터(물체)					168
38	일상생활 작업 및 명령 수행 데이터(임무수행 명령어)					200
39	지능형 양봉 데이터	14	-	2022. 12. 31.	2024. 1. 31.	455
40	식생 탄소 포집량 식별 데이터	14	-	2022. 12. 31.	2025. 6. 5.	260
41	한국어 지식기반 관계 데이터	14	-	2022. 12. 31.	2024. 9. 25.	1,728
42	자전거도로 주행 데이터	14	-	2022. 12. 31.	2024. 6. 7.	928
43	조선·해양플랜트 P&ID 심볼 식별 데이터	13	-	2022. 12. 31.	2024. 12. 3.	159
44	제조업 노동자 근골격계 부담요인 예방을 위한 인공지능 데이터 구축	11	-	2022. 12. 31.	2024. 8. 29.	218
45	산업용 햄프 생육 이미지 및 환경 데이터	11	-	2022. 12. 31.	2024. 3. 31.	164
46	지자체 도로부속시설물 파손 데이터	11	가사	2022. 12. 31.	2024. 5. 31.	376
47	구강 이미지 데이터	11	-	2022. 12. 31.	2024. 1. 29.	17

연번	데이터명	정부출연금	주관기관명	데이터 구축일	폐업일	다운로드 수 ^{주)}
48	토지피복지도 항공위성 이미지	11	-	2022. 12. 31.	2025. 6. 5.	470
49	생활폐기물 데이터 활용·환류	11	-	2022. 12. 31.	2024. 3. 20.	1,190
50	법률안 검토 보고서 요약 데이터	28	-	2023. 12. 31.	2024. 9. 25.	698
51	국회 회의록 기반 지식 검색 데이터					1,031
52	식용곤충 사육 자동화 데이터	11	-	2023. 12. 31.	2024. 1. 31.	98
53	지능형 스마트 미꾸리 종자생산 시스템 및 양식 데이터	17	-	2023. 12. 31.	2025. 4. 30.	222
54	일상생활 작업 및 명령 수행 데이터(공간)	37	-	2023. 12. 31.	폐업 진행 중	171
55	일상생활 작업 및 명령 수행 데이터(물체)					268
56	일상생활 작업 및 명령 수행 데이터(임무수행 명령어)					133
57	오피스 문서 생성 데이터	18	-	2024. 12. 31.	폐업 진행 중	1,801
58	시각화 자료 질의응답 데이터 (1692)					1,692
59	멀티모달 정보검색 데이터					1,066
60	교과단계별 교과 데이터	15	-	2024. 12. 31.	폐업 진행 중	4,202
61	국어 교과 지문형 문제 데이터					2,711
62	수학 교과 문제 풀이과정 데이터					3,987
63	제조환경 사람-로봇 공유 작업 데이터	12	-	2024. 12. 31.	폐업 진행 중	378
64	가정환경 사람-로봇 공유 작업 데이터					478
65	심리상담 데이터	6	-	2024. 12. 31.	2025. 3. 31.	1,930
66	대기오염 배출원 공간 분포 데이터	6	-	2024. 12. 31.	2025. 6. 5.	2,152
계	66종	828	17개 업체			

주: 데이터 다운로드 수는 2025년 12월 말 기준
자료: 지능정보사회원 제출자료 재구성

[별표 4]

폐업한 주관기관의 학습용 데이터 관련 민원 접수 및 처리 현황

연번	사업수행기관명	데이터명 (민원 접수일)	회신일	이용자 문의 내역 및 답변 내역
1	☐재 (폐업)	지자체 도로정비 AI 학습용 데이터 (2024. 7. 30.)	2024. 8. 8.	▪ (질의): 포트홀 이미지 및 객체 태깅 관련 개선 요청 ▪ (답변): 수차례 구축업체에 전달하여 회신을 받으려 하였으나 <u>구축업체의 폐업으로 전달되지 못해 답변이 어려운 것으로 확인</u>됩니다. 현재 AI 허브에 공개되고 있는 해당 데이터 및 산출물 이외에 추가적인 수정 보완이나 자료 제공이 어려운 점 양해 부탁드립니다.
2	- (폐업)	제조업 노동자 근골격계 부담요인 예방을 위한 인공지능 데이터 구축 (2025. 3. 19.)	2025. 3. 21.	▪ (질의): 다운로드받은 실제 데이터가 소개 페이지 내용과 다름 ▪ (답변): 문의하신 사항은 구축업체의 확인이 필요한 내용이므로, 해당 업체에 수차례 이메일과 전화로 연락을 시도하였으나, <u>구축 주관 업체 폐업 및 수행 실무자 퇴사 등의 관련 업체 내부 사정</u>으로 인해 문의 주신 내용 및 이력이 공유되지 않고 있는 상황입니다. 이에 따라, 문의하신 내용에 대한 답변을 드리기 어려운 점 깊이 사과드립니다.
3	- (폐업 절차 진행 중)	상용 자율주행차 주간 도심도로 데이터 (2025. 5. 9.)	2025. 5. 12.	▪ (질의): 좌표 관련 문의 ▪ (답변): 문의하신 좌표 변환 및 투영 방식과 같은 데이터 관련 문의나 추가 정보에 대한 사항은 구축 수행 기관에 전달하여 회신을 받아 보려 하였으나 <u>구축 수행기관의 내부 사정(파산, 연락두절 등)</u>으로 인해, 공개된 자료 외에 추가적인 자료나 <u>학습 방법 등의 설명은 제공하기 어려운 점 양해</u> 부탁드립니다. 따라서, 시각화 또는 좌표 투영 등의 처리 과정은 사용자의 연구 목적과 환경에 맞게 별도로 구현 및 적용해주셔야 하며, [구축활용 가이드 등]을 참고하시어 활용하여 주시기 바랍니다.
4	- (업종 전환)	가구·가전·사무기기 사용 모션캡처 데이터 (2025. 5. 13.)	2025. 5. 13.	▪ (질의): 모델 환경 설치 가이드에서 test.npy, test.pkl 파일을 다운로드해서 테스트를 할 수 있다고 작성되어 있으나, 제공된 파일에는 test.npy, test.pkl이 없음 ▪ (답변): 테스트용 데이터셋이 필요하신 경우, 제공된 원천 데이터를 기반으로 전처리 절차를 직접 수행하여 val_data_joint.npy, val_label.pkl 파일을 생성해주셔야 함을 안내드립니다. 아울러, <u>해당 기관의 폐업으로 인해 기존 홈페이지 문서 내용의 수정 및 추가 안내가 어려운 점 넓은 양해</u> 부탁드립니다.
5	- (폐업 절차 진행 중)	노변기지국 송·수신 V2X 메시지 데이터 (2025. 5. 16.)	2025. 5. 16.	▪ (질의): 노변 기지국 또는 센서 설치 장소에 대한 위도, 경도 값에 대한 정보 요청 ▪ (답변): 문의하신 기지국 또는 센서 설치 지점의 위도·경도 정보는 제출되거나 보유하지 않았습니다. 또한, <u>해당 데이터의 구축 수행기관은 현재 내부 사정(폐업 등)으로 인해 추가적인 정보 제공이나 기술 문의가 어려운 상황임을 양해</u> 부탁드립니다. 따라서, 공개된 데이터 및 산출물(데이터설명서, 구축활용가이드 등) 외의 추가적인 자료의 제공은 어려운 점 양해 부탁드립니다.

연번	사업수행기관명	데이터명 (민원 접수일)	회신일	이용자 문의 내역 및 답변 내역
6	개아 (내부 사정)	지역안전재난(산불) 방재의 고도화를 위 한 대규모 인공지능 데이터베이스 구축 (2025. 8. 3., 8. 11.)	2025. 8. 5, 8. 12.	▪ (질의): docker load에서 EOF ERROR 관련 문의 등 ▪ (답변): 실제 확인 결과, 제공된 forest_fire.tar 파일 내 일부 layer.tar 파일이 비어 있는 상태로 확인되었으며, 해당 사항에 대해 수차례 수행기관에 확인을 요청하였으나 해당 기관은 현재 <u>운용 종료(폐업)</u> 상태로 해당 구성의 정확한 경위 확인이 어려운 상황입니다.
7	- (폐업 절차 진행 중)	상용 자율주행차 주간 자동차 전용도로 데이터 (2025. 11. 20.)	2025. 11. 20.	▪ (질의): 카메라 설치 높이, 카메라 화각 및 초점거리 문의 ▪ (답변): 카메라 설치 높이, 화각(FOV), 초점거리 등 촬영 장비의 세부 파라미터는 과제 수행 과정에서 별도로 수집·보관되지 않았으며, 공개된 문서에도 포함되어 있지 않습니다. 아울러 문의주신 추가 정보는 구축 수행 기관에 확인을 요청하였으나, 해당 기관의 내부 사정(폐업 등)으로 인해, 공개된 산출물 외 추가 자료 제공이 어려운 점 양해 부탁드립니다.

자료: 지능정보사회원 제출자료 재구성

[별표 5]

폐업한 참여기관의 학습용 데이터 관련 민원 접수 및 처리 현황

연번	사업수행기관명	데이터명 (민원 접수일)	회신일	이용자 문의 내역 및 답변 내역
1	가자 (폐업)	저음질 전화망 음성인식 데이터 (2025. 2. 19.)	2025. 2. 27.	▪ (질의): 데이터 전사와 음성 매칭이 안 되는 경우 다수 존재. 음성과 전사에 대한 전체적인 검수 필요 ▪ (답변): 데이터의 수정 보완은 구축·수행 기관만 가능하여 구축업체에 전달하고 회신받으려 하였으나 해당 구축업체의 내부 사정 등으로 인해 답변이 어려운 것으로 확인되었습니다. 이로 인해 해당 데이터에 대한 추가적인 수정 보완이나 자료 제공이 어려운 점 양해 부탁드립니다.
2	- (폐업)	상수원-취수원 통합 수질 및 녹조 데이터 (2025. 3. 5.)	2025. 3. 20.	▪ (질의): 도커 이미지파일(docker image: NIA_95_SPEC.tar), 소스코드 또는 해당 이미지 파일 제공 및 접속 관련 문의 ▪ (답변): 문의하신 사항은 구축업체의 확인이 필요한 내용이므로, 해당 업체에 수차례 이메일과 전화로 연락을 시도하였으나, AI 학습 모델 개발에 참여한 수행기관의 실무자 퇴사 등의 사유로 인해 담당자와의 연결이 어려운 상황입니다. 이로 인해 답변이 어려운 점 다시 한번 사과드립니다.
3	- (폐업)	구음장에 음성인식 데이터 (2025. 3. 17.)	2025. 3. 18.	▪ (질의): 데이터 설명서와 구축활용가이드상 정보가 데이터세트의 분류와 맞지 않는 것에 대한 질의 ▪ (답변): 해당 데이터는 2021년에 구축된 데이터로, 구축 당시 수행기관의 폐업으로 인해 문의자님께서 원하시는 답변을 드리지 못한 점에 대해 진심으로 사과드립니다.
4	가자 (폐업)	에세이 글 평가 데이터 (2025. 5. 1.)	2025. 5. 8.	▪ (질의): 데이터(문장) 중복이 다수 존재 ▪ (답변): 문의하신 학습 및 검증 데이터 내에 동일하거나 유사한 문장이 포함된 사례를 확인하였으나, 현재 데이터 구축기관이 폐업한 상태로 추가적인 정정이나 보완이 어려운 상황임을 양해 부탁드립니다. 또한, 당시의 데이터 문장 및 구성 방식에 대해서도 내부적으로 추가 확인이 어려운 점 너그럽이 이해해 주시기 바랍니다. 이러한 사정을 고려하시어, 본 데이터세트를 활용하실 때에는 유사하거나 중복된 항목이 포함되어 있음을 감안하셔서 분석 또는 학습 목적에 맞게 해당 항목을 선별적으로 필터링하거나 제외하여 사용해 주시기를 권장드립니다.

자료: 지능정보사회원 제출자료 재구성